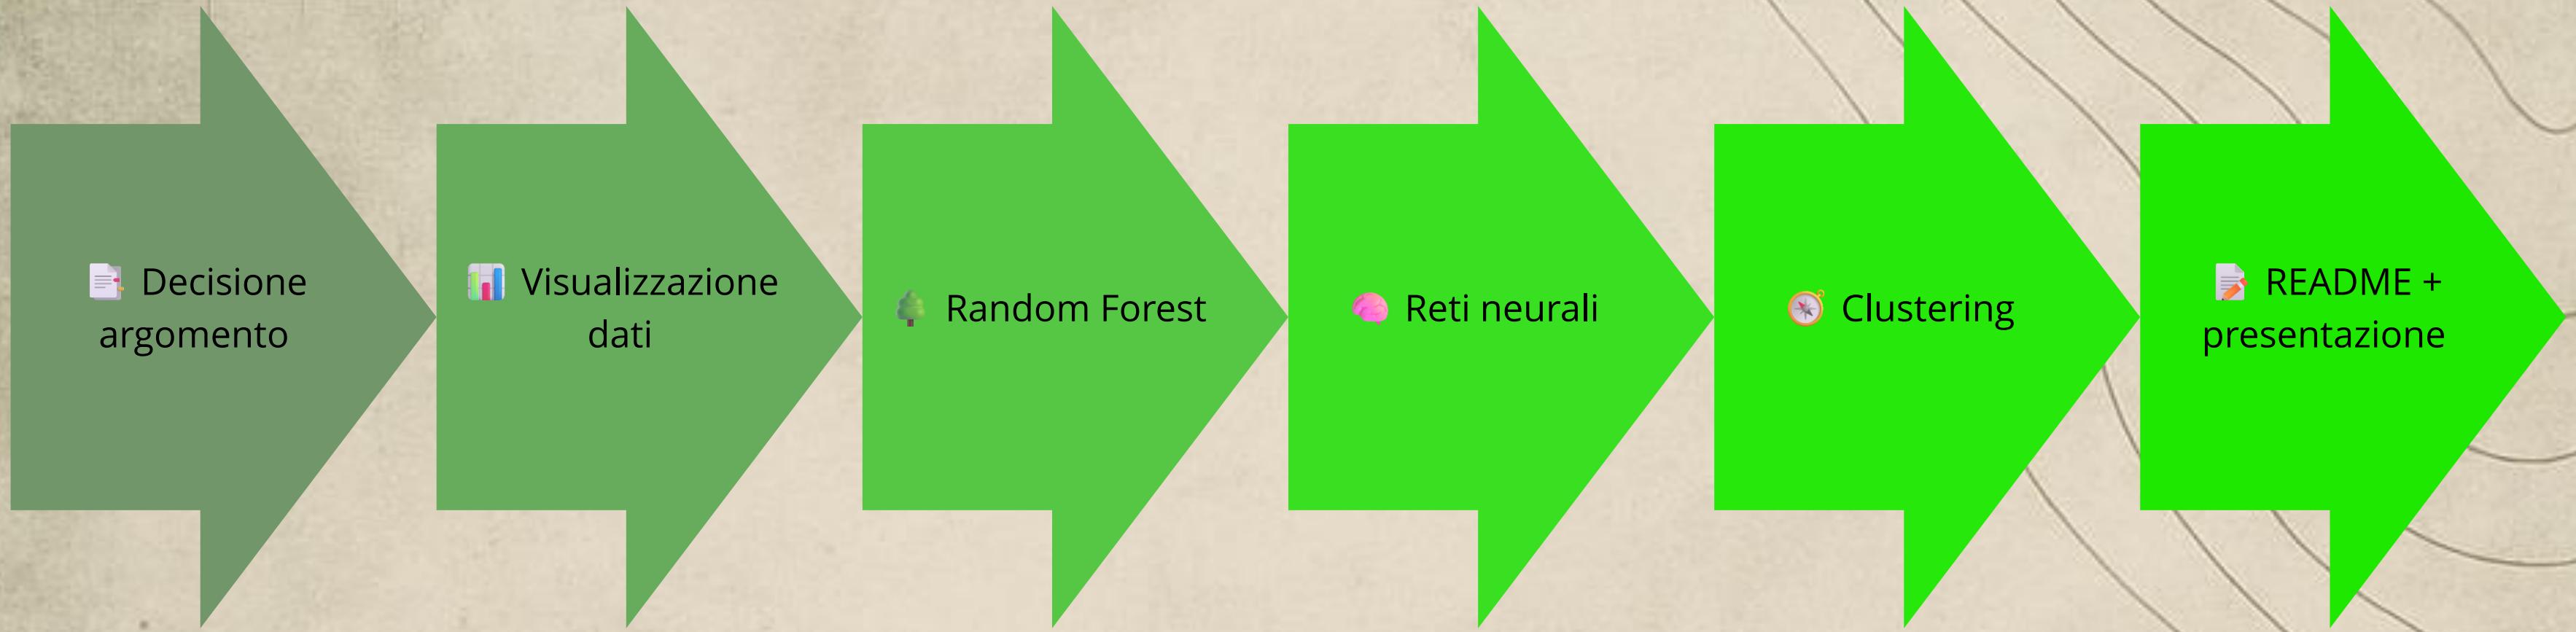




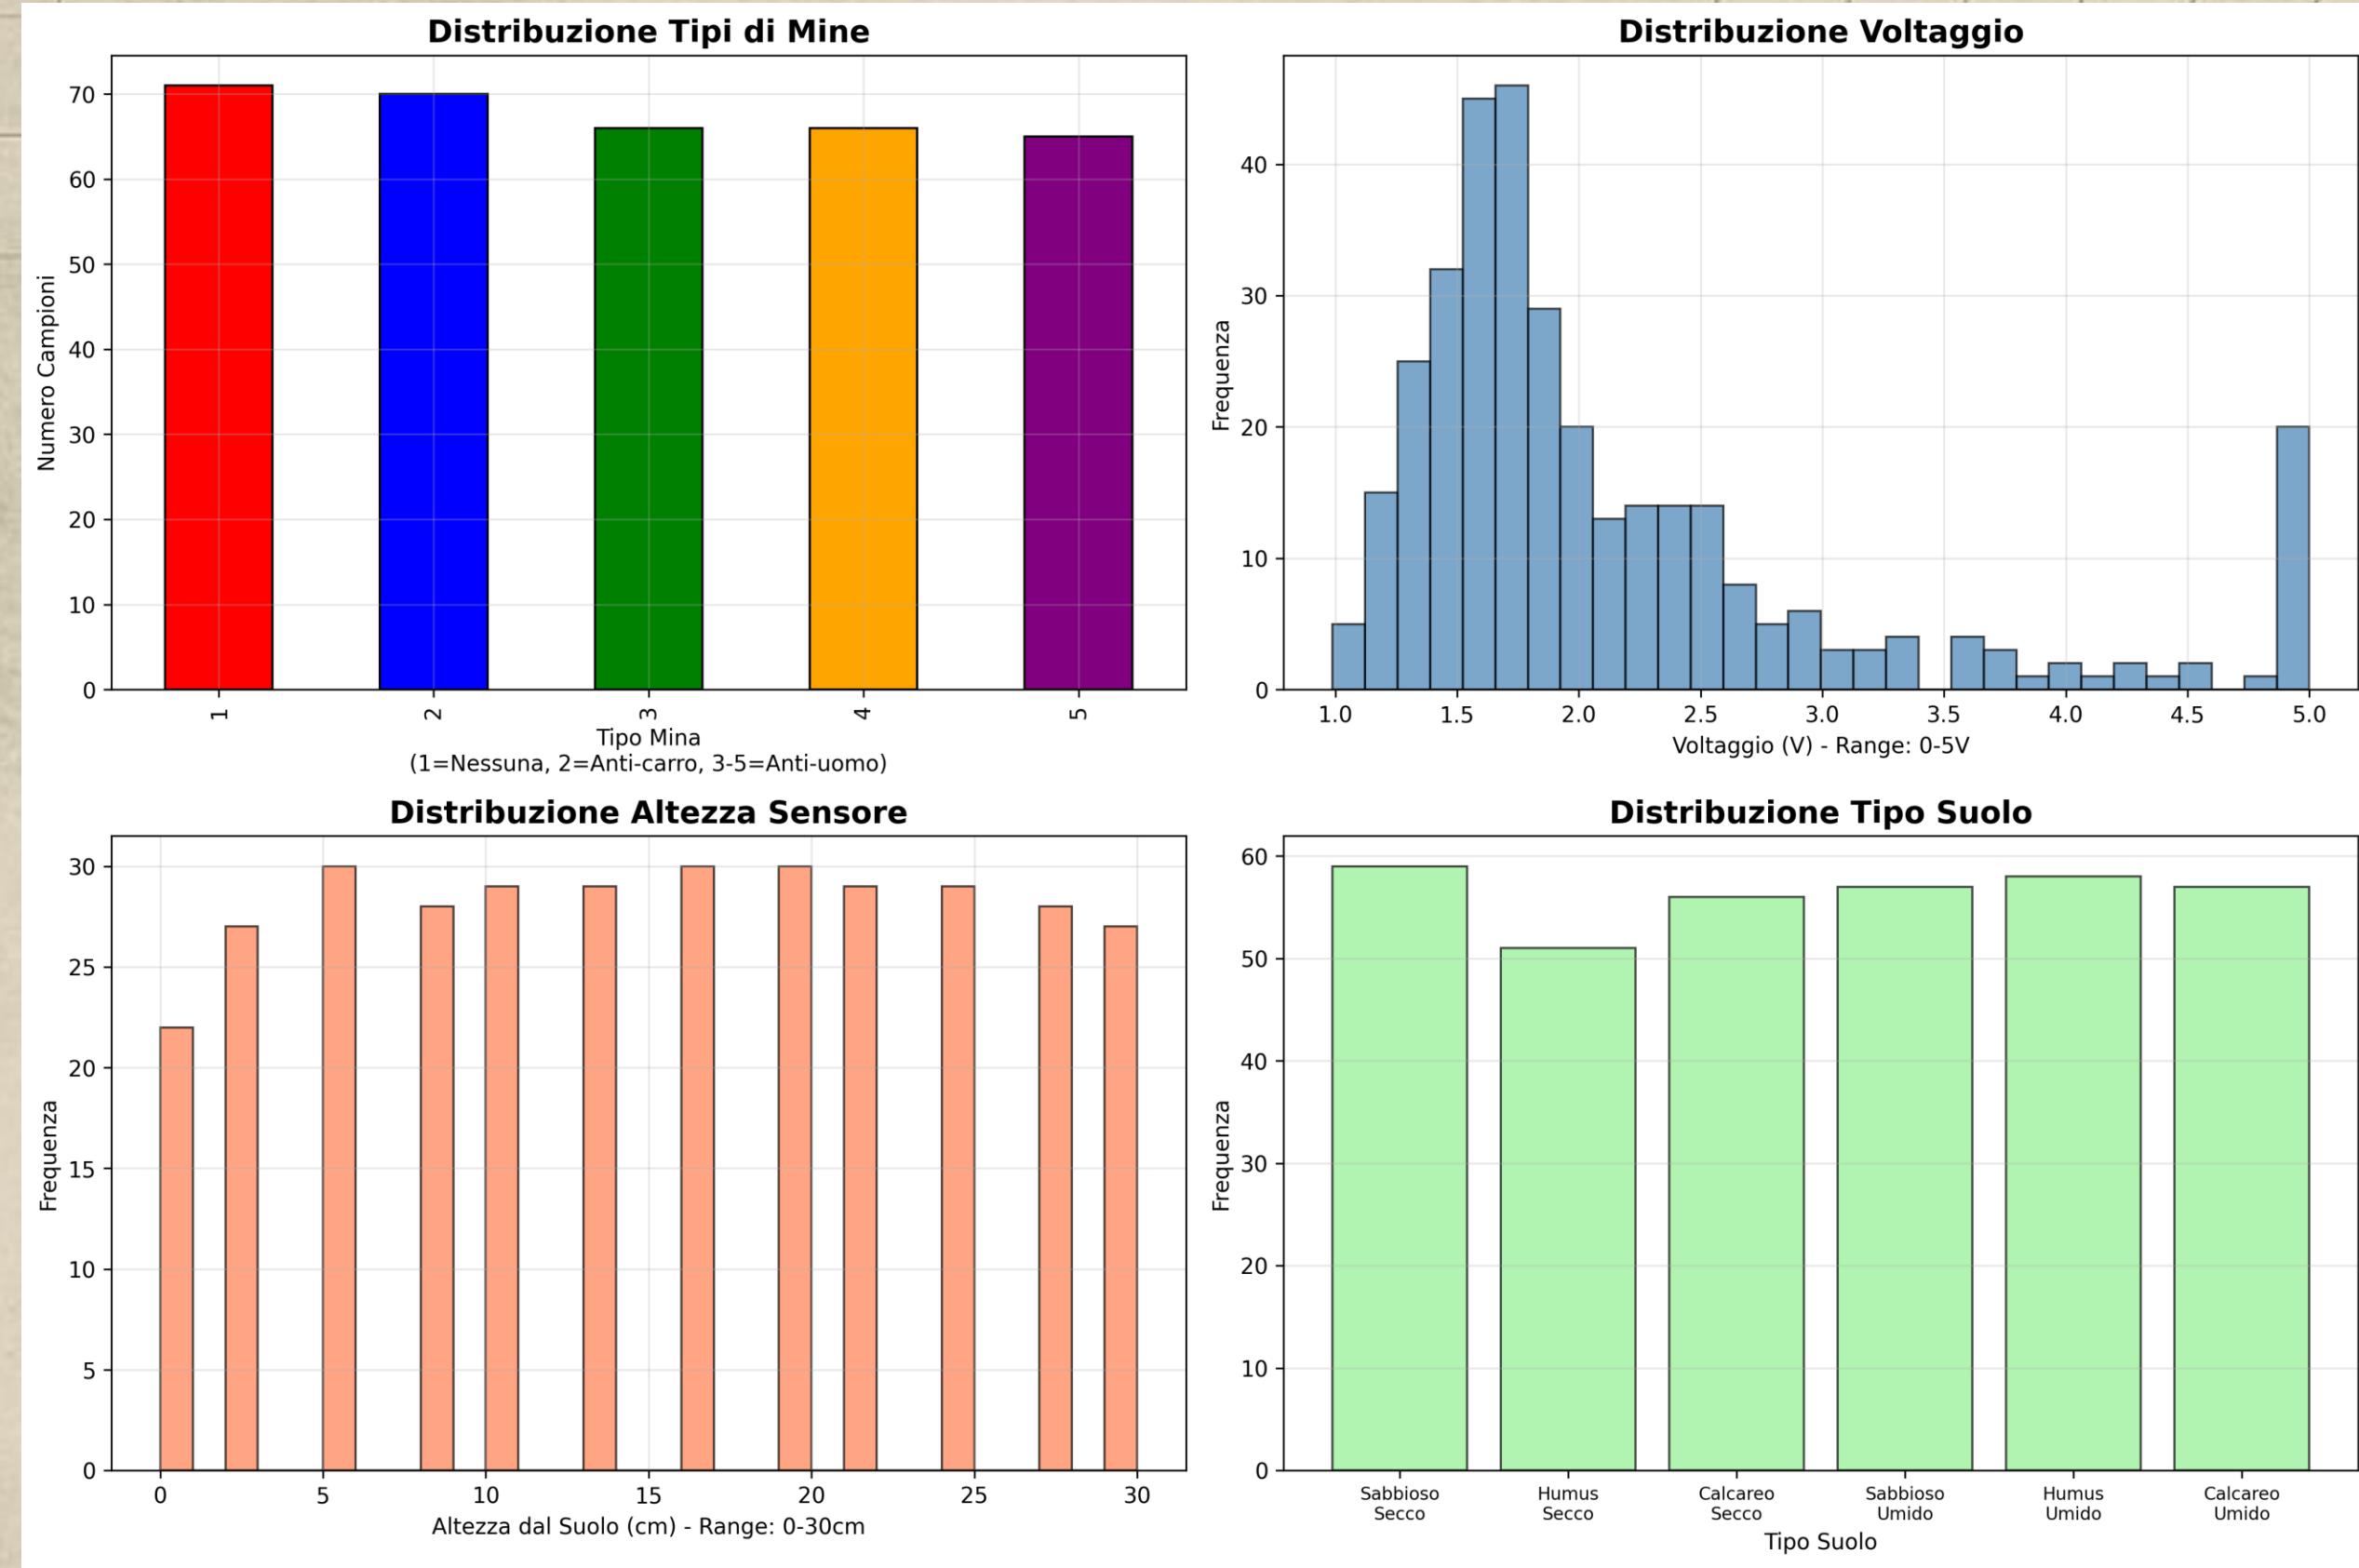
IL RILEVAMENTO DELLE MINE TERRESTRI

Progetto a cura di
Acosta Gaia Luna e
Cysa Bujar

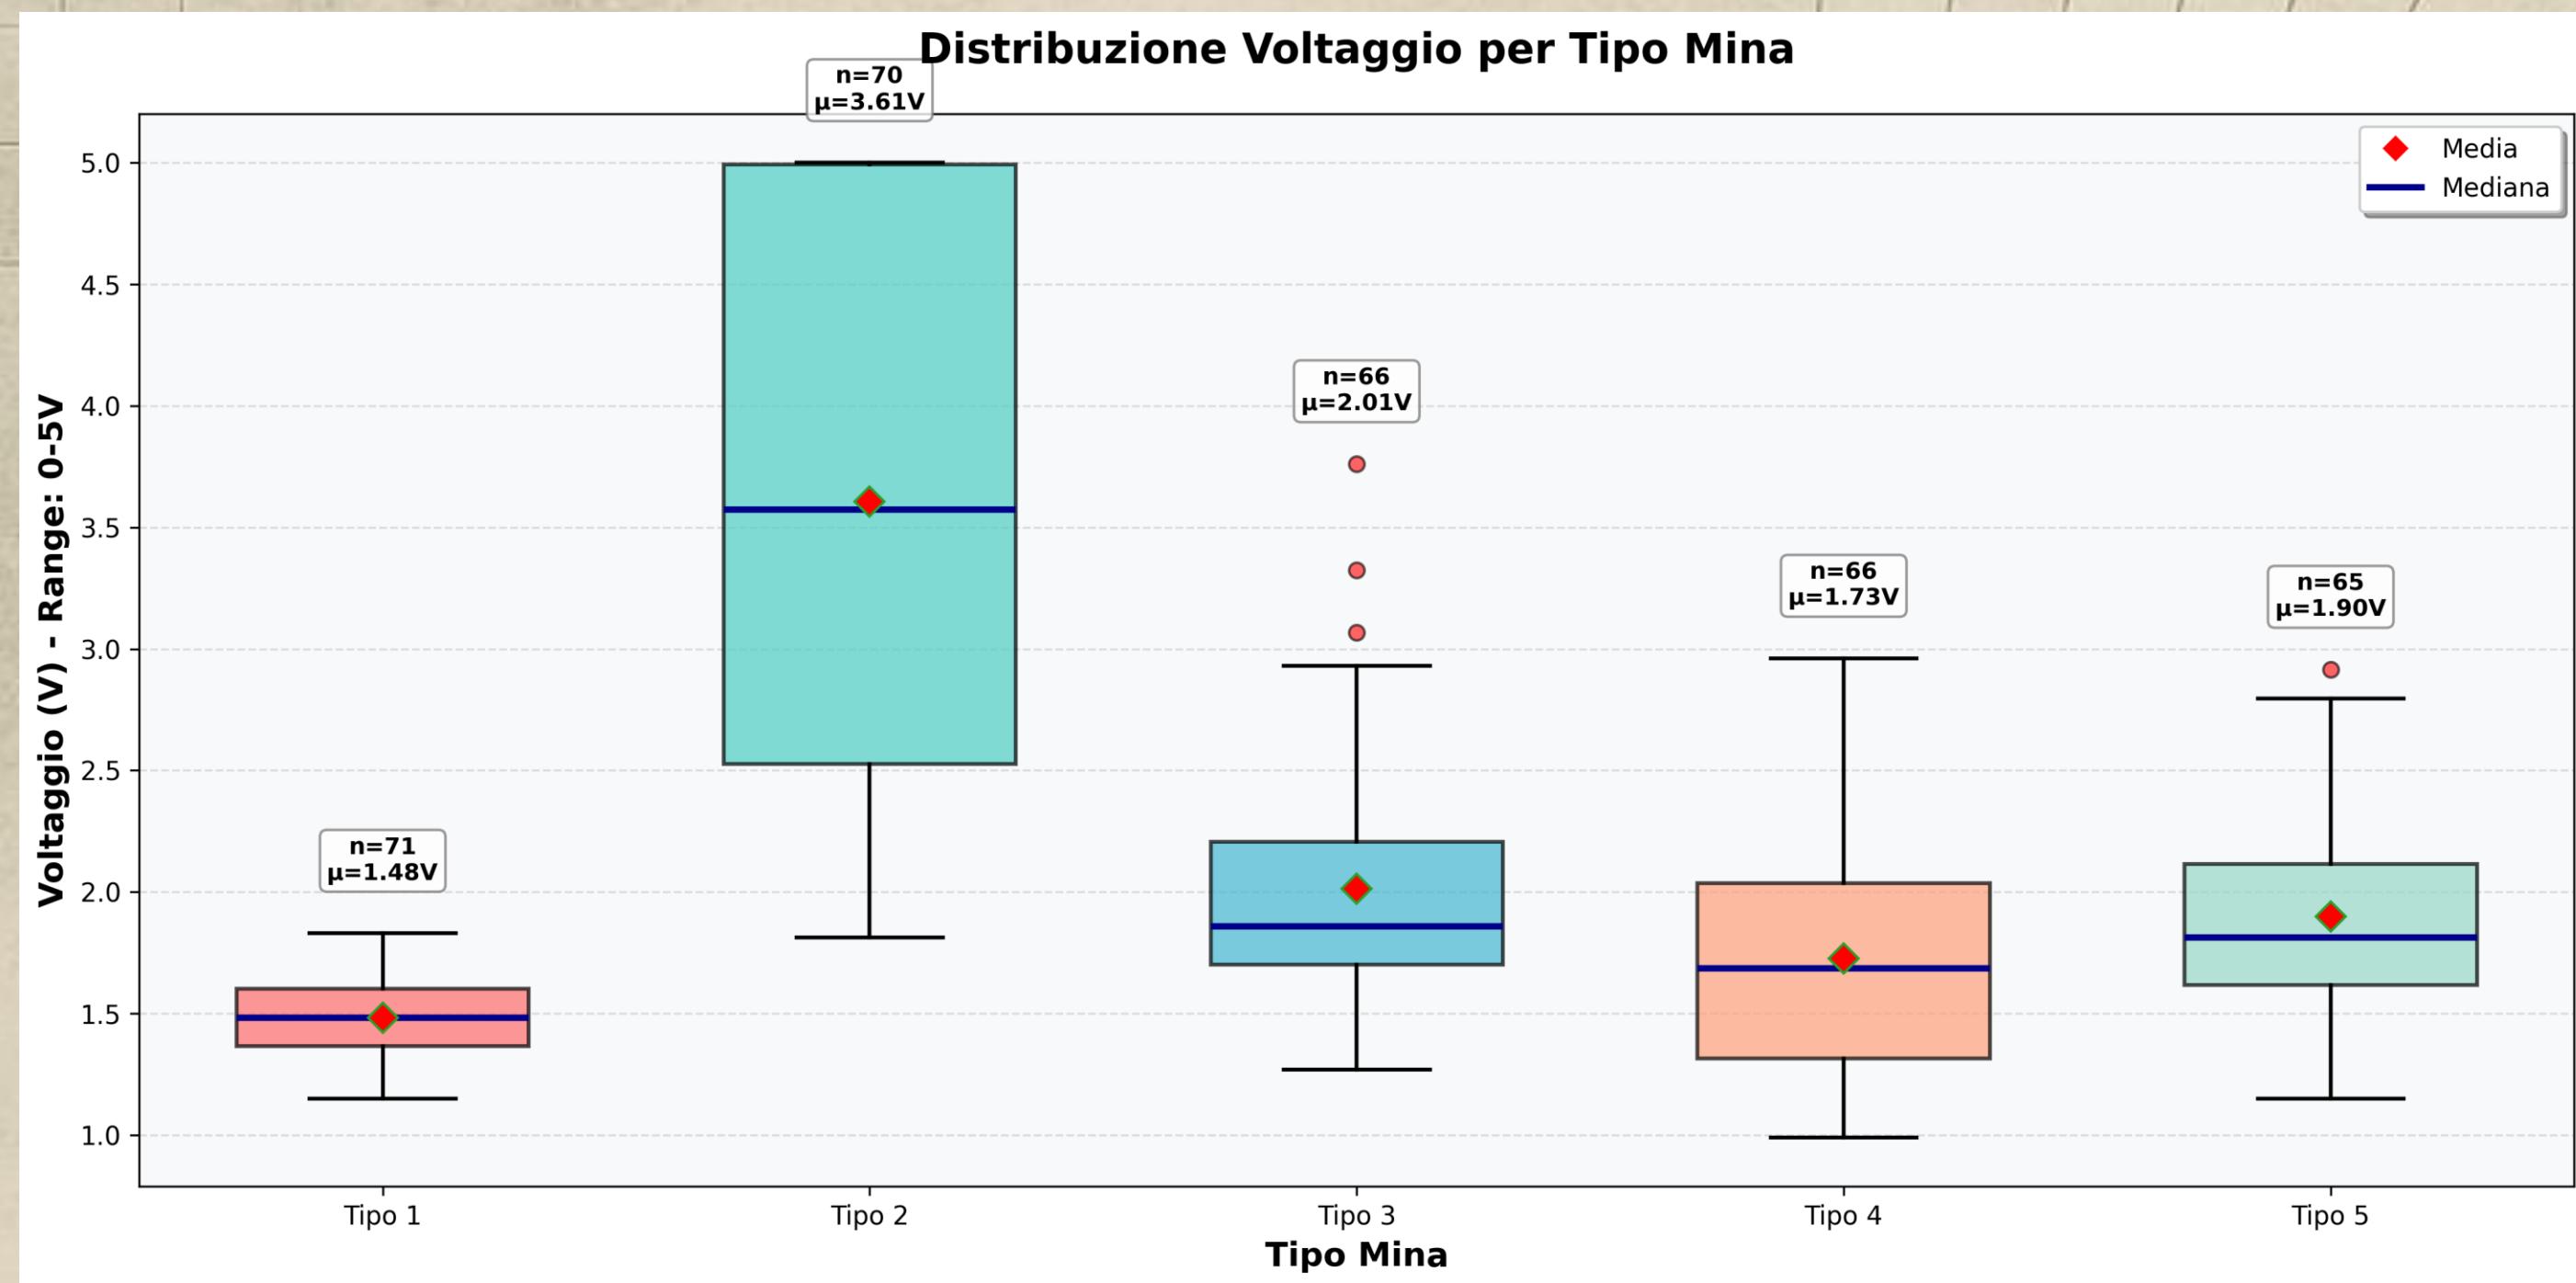
LE FASI DEL PROGETTO



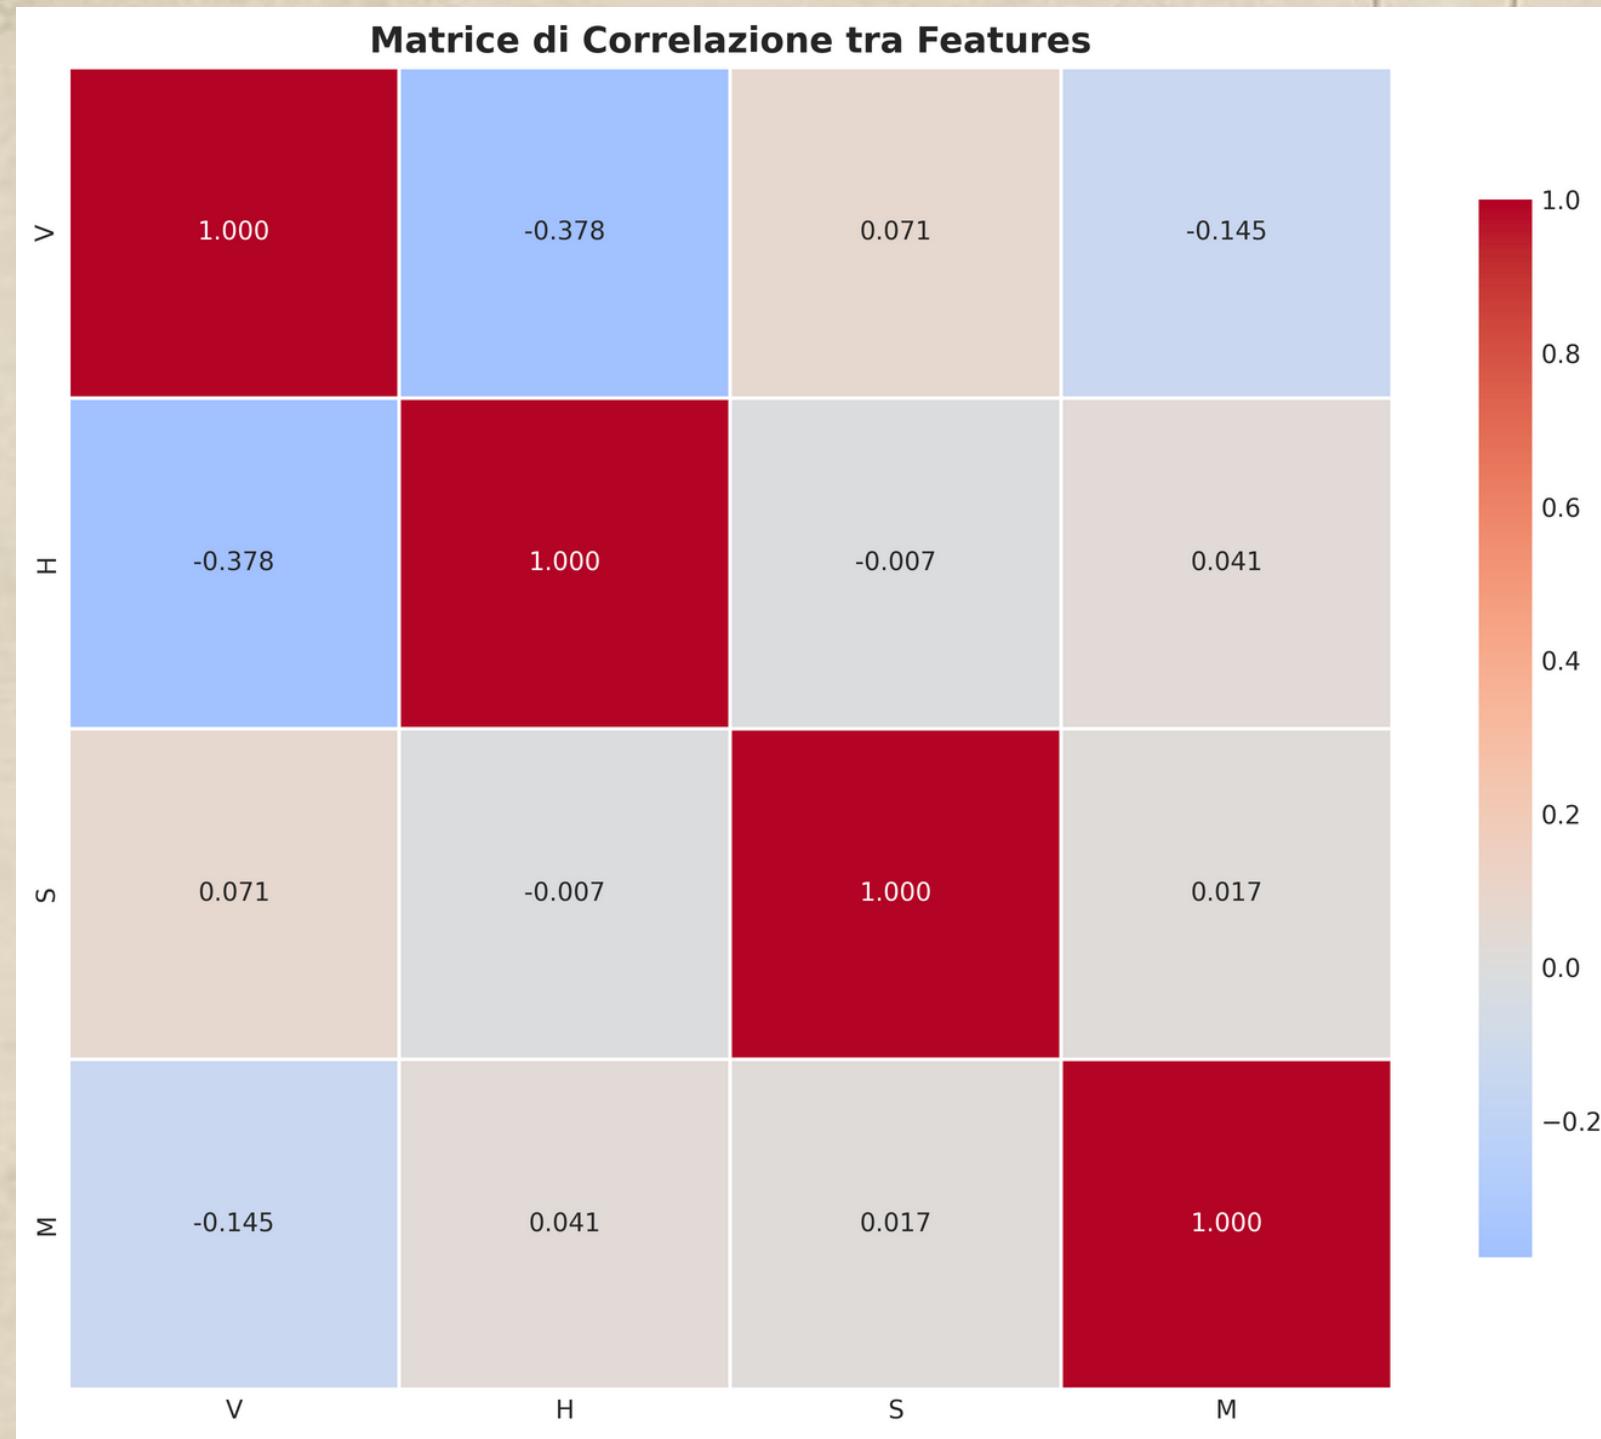
VISUALIZZAZIONE DATI



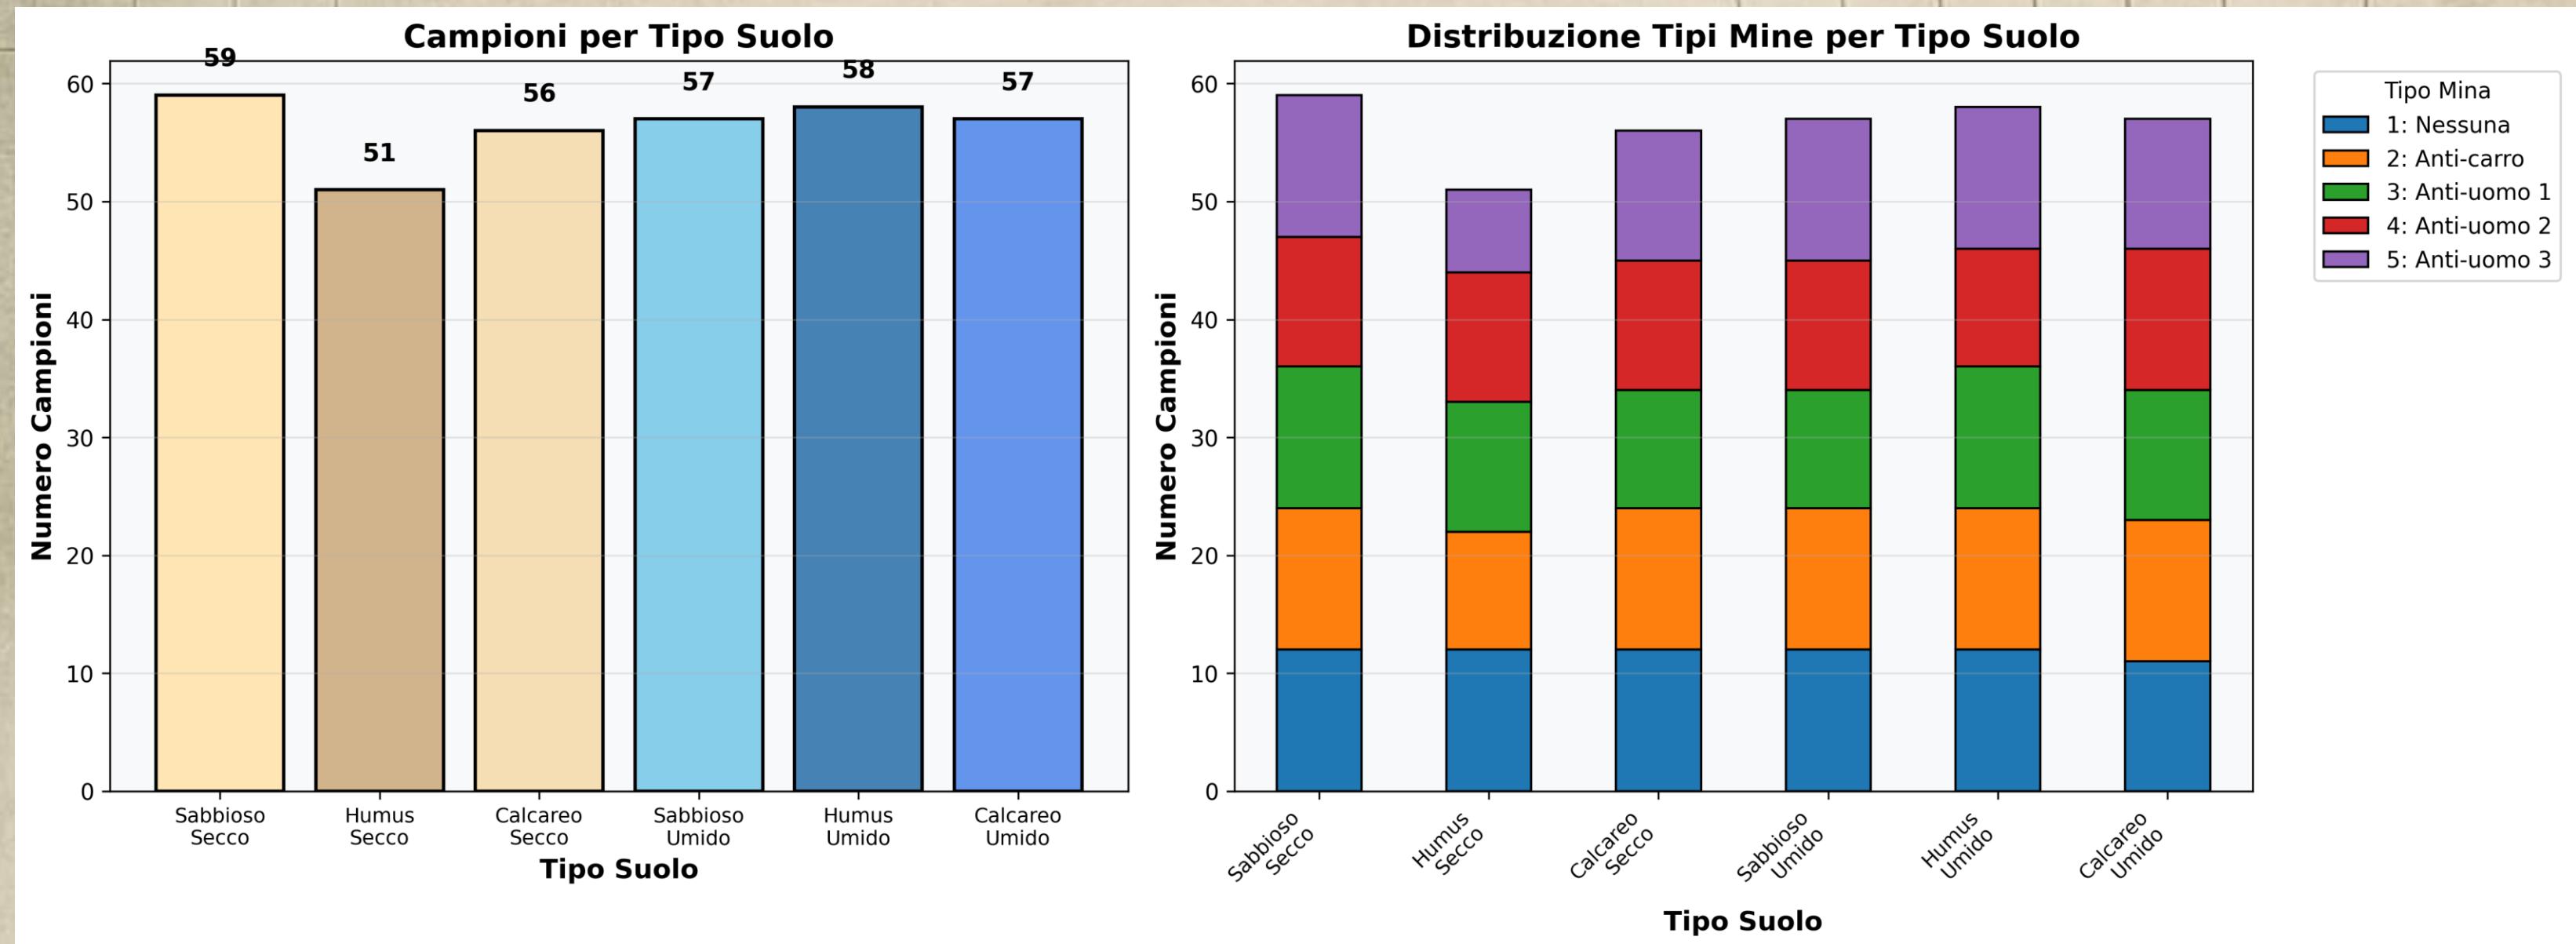
VISUALIZZAZIONE DATI



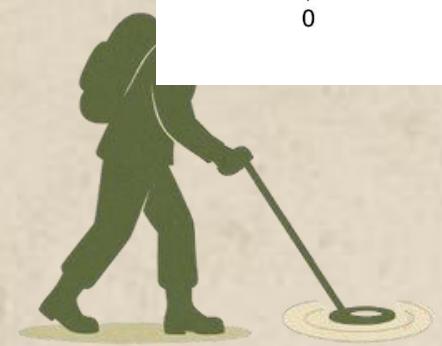
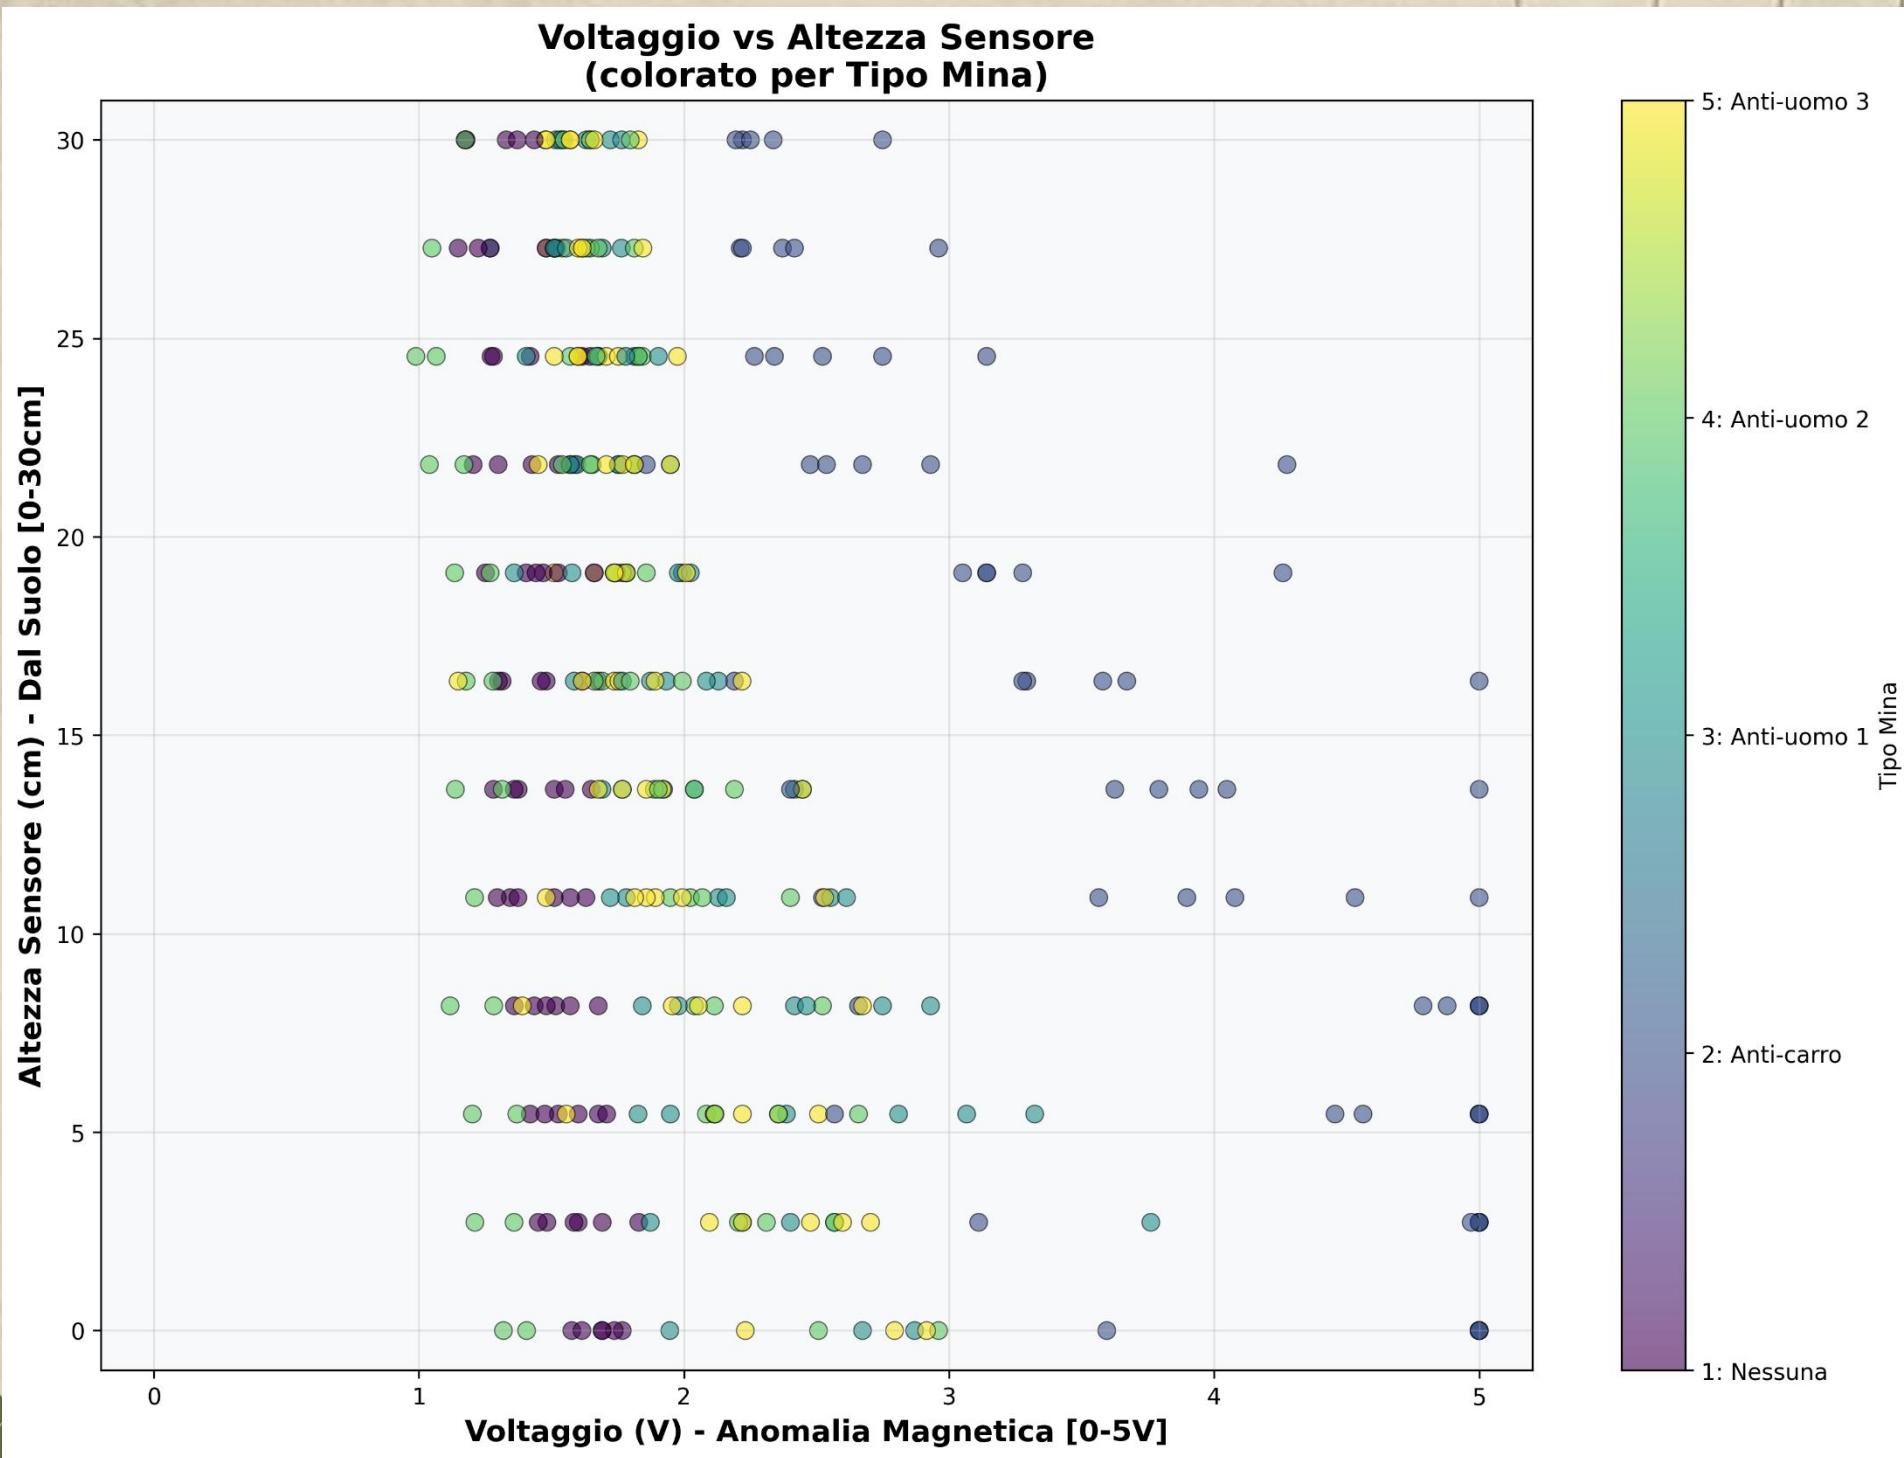
VISUALIZZAZIONE DATI



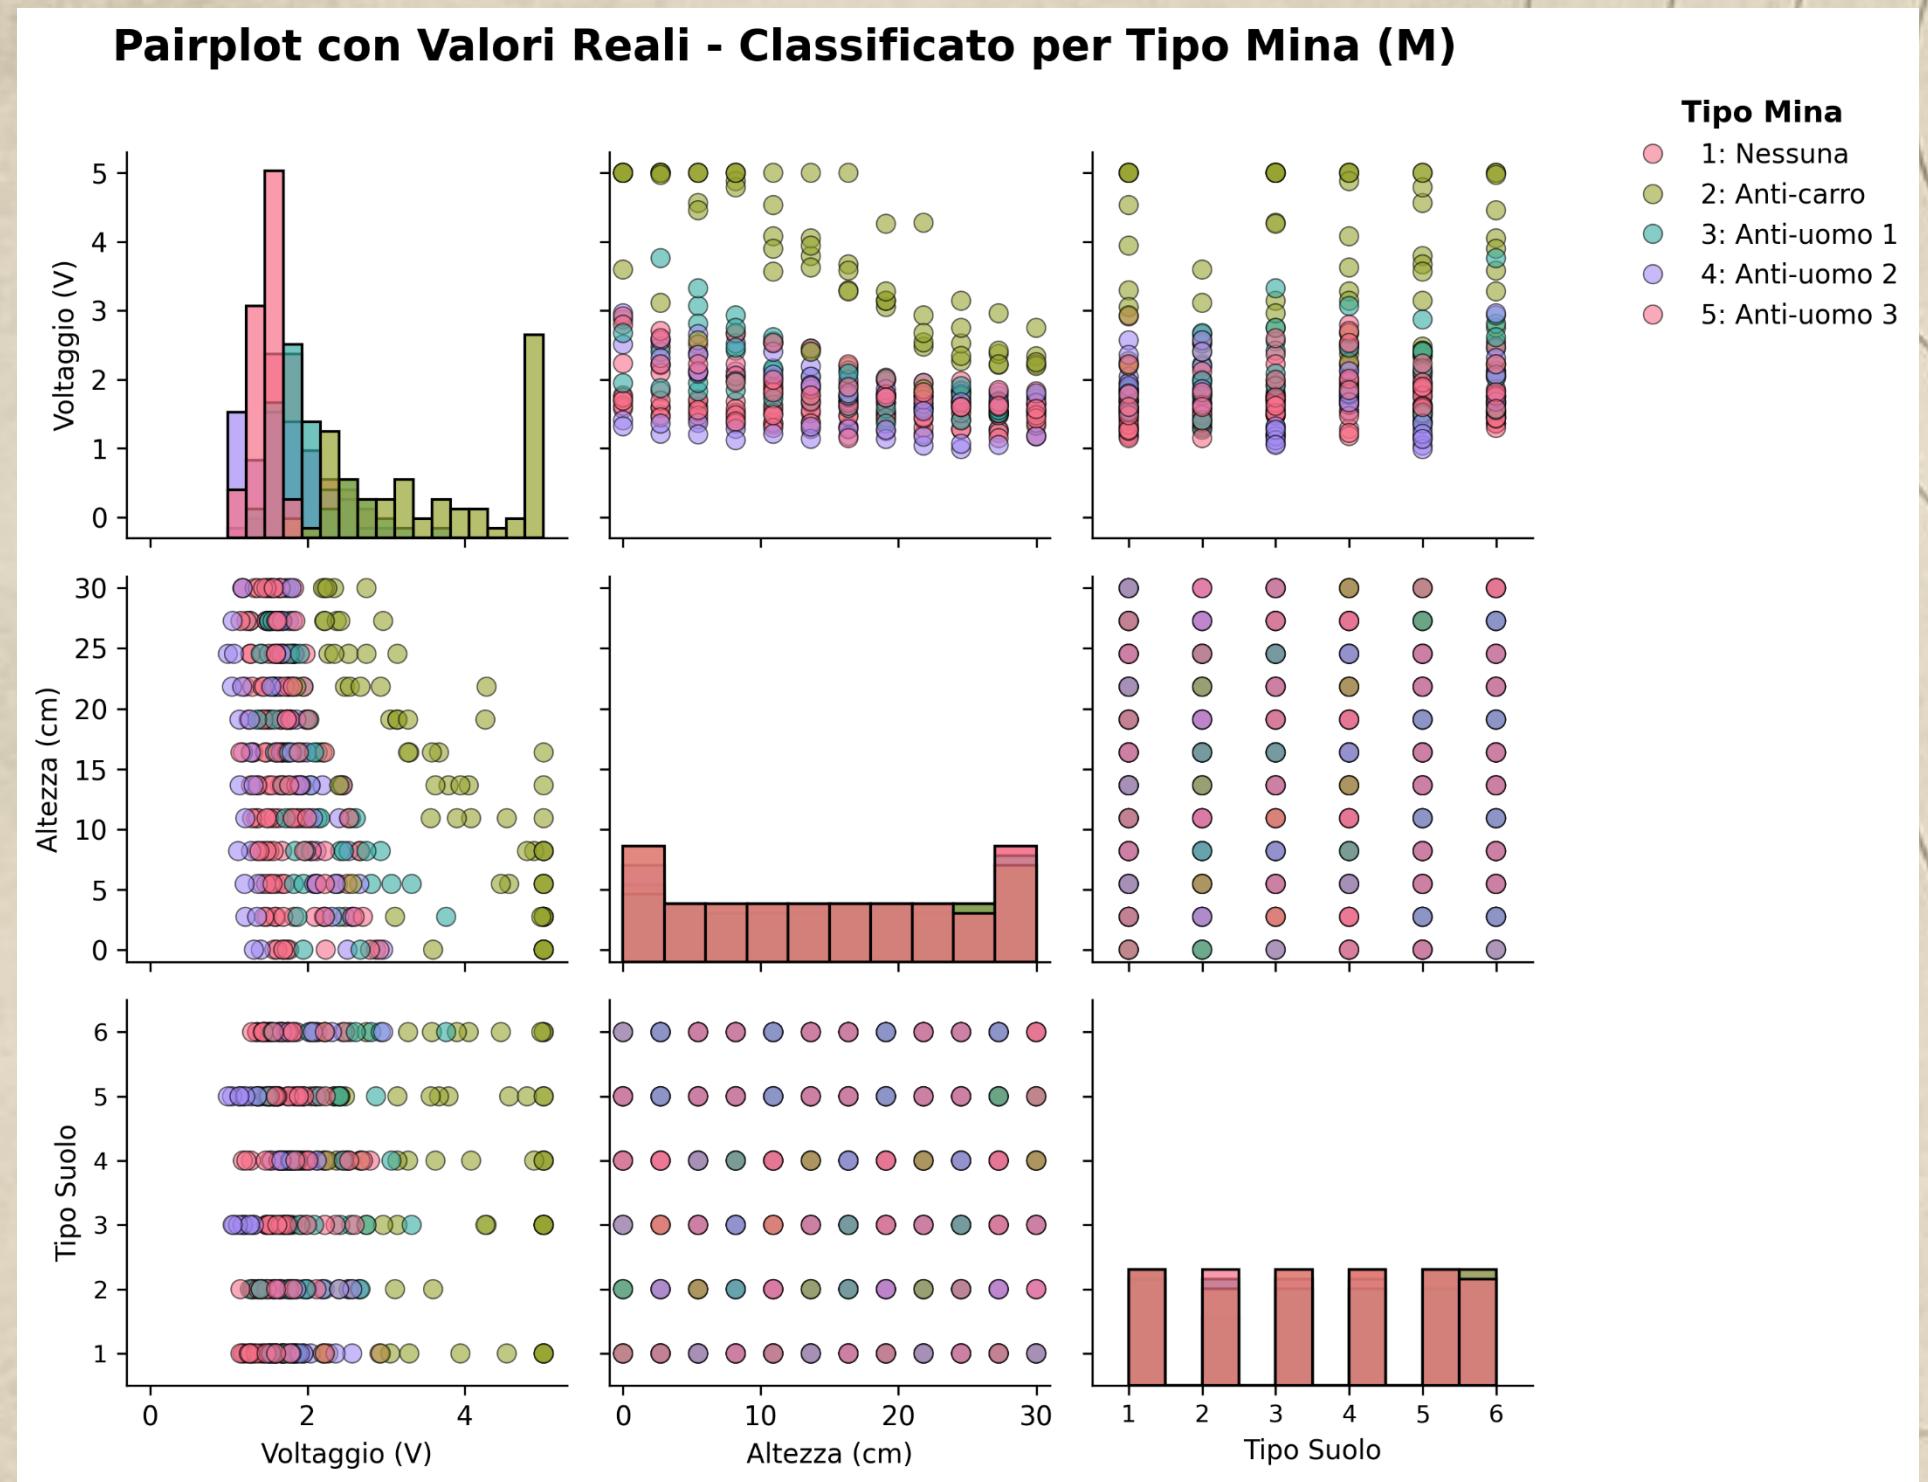
VISUALIZZAZIONE DATI



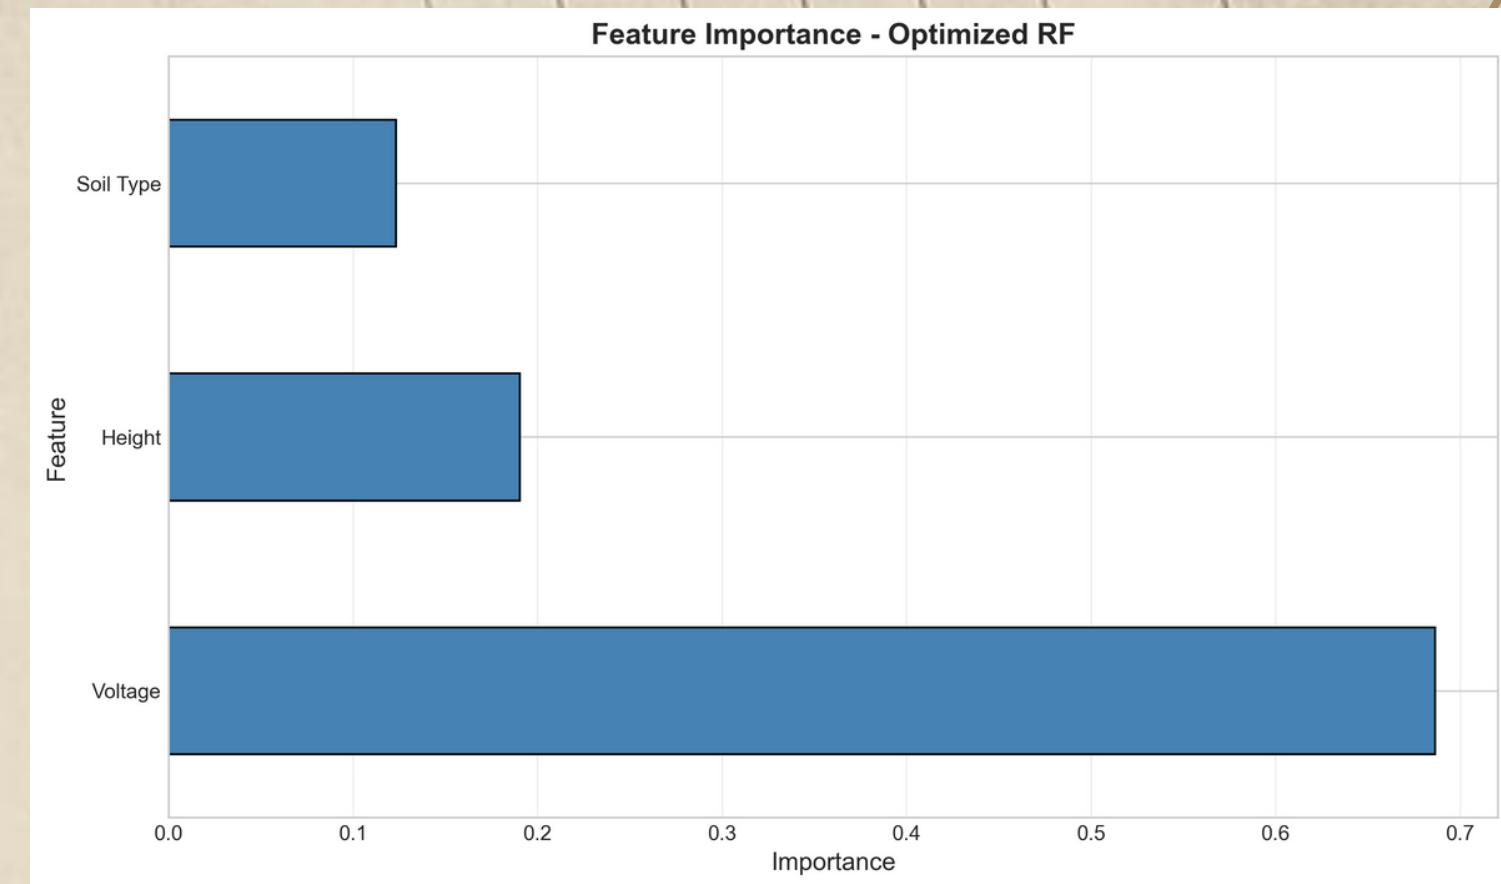
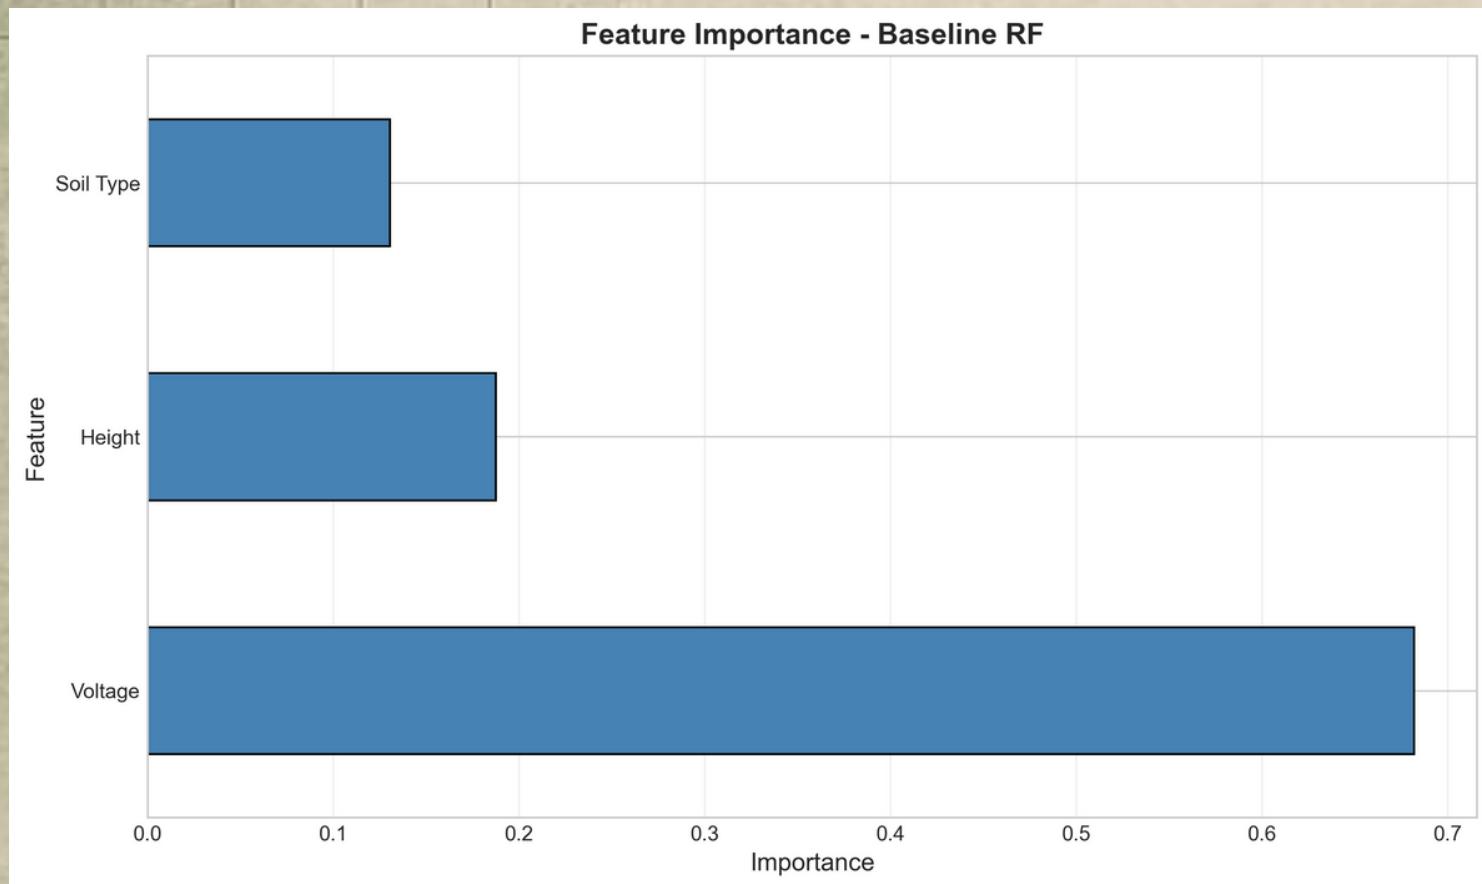
VISUALIZZAZIONE DATI



VISUALIZZAZIONE DATI



RANDOM FOREST

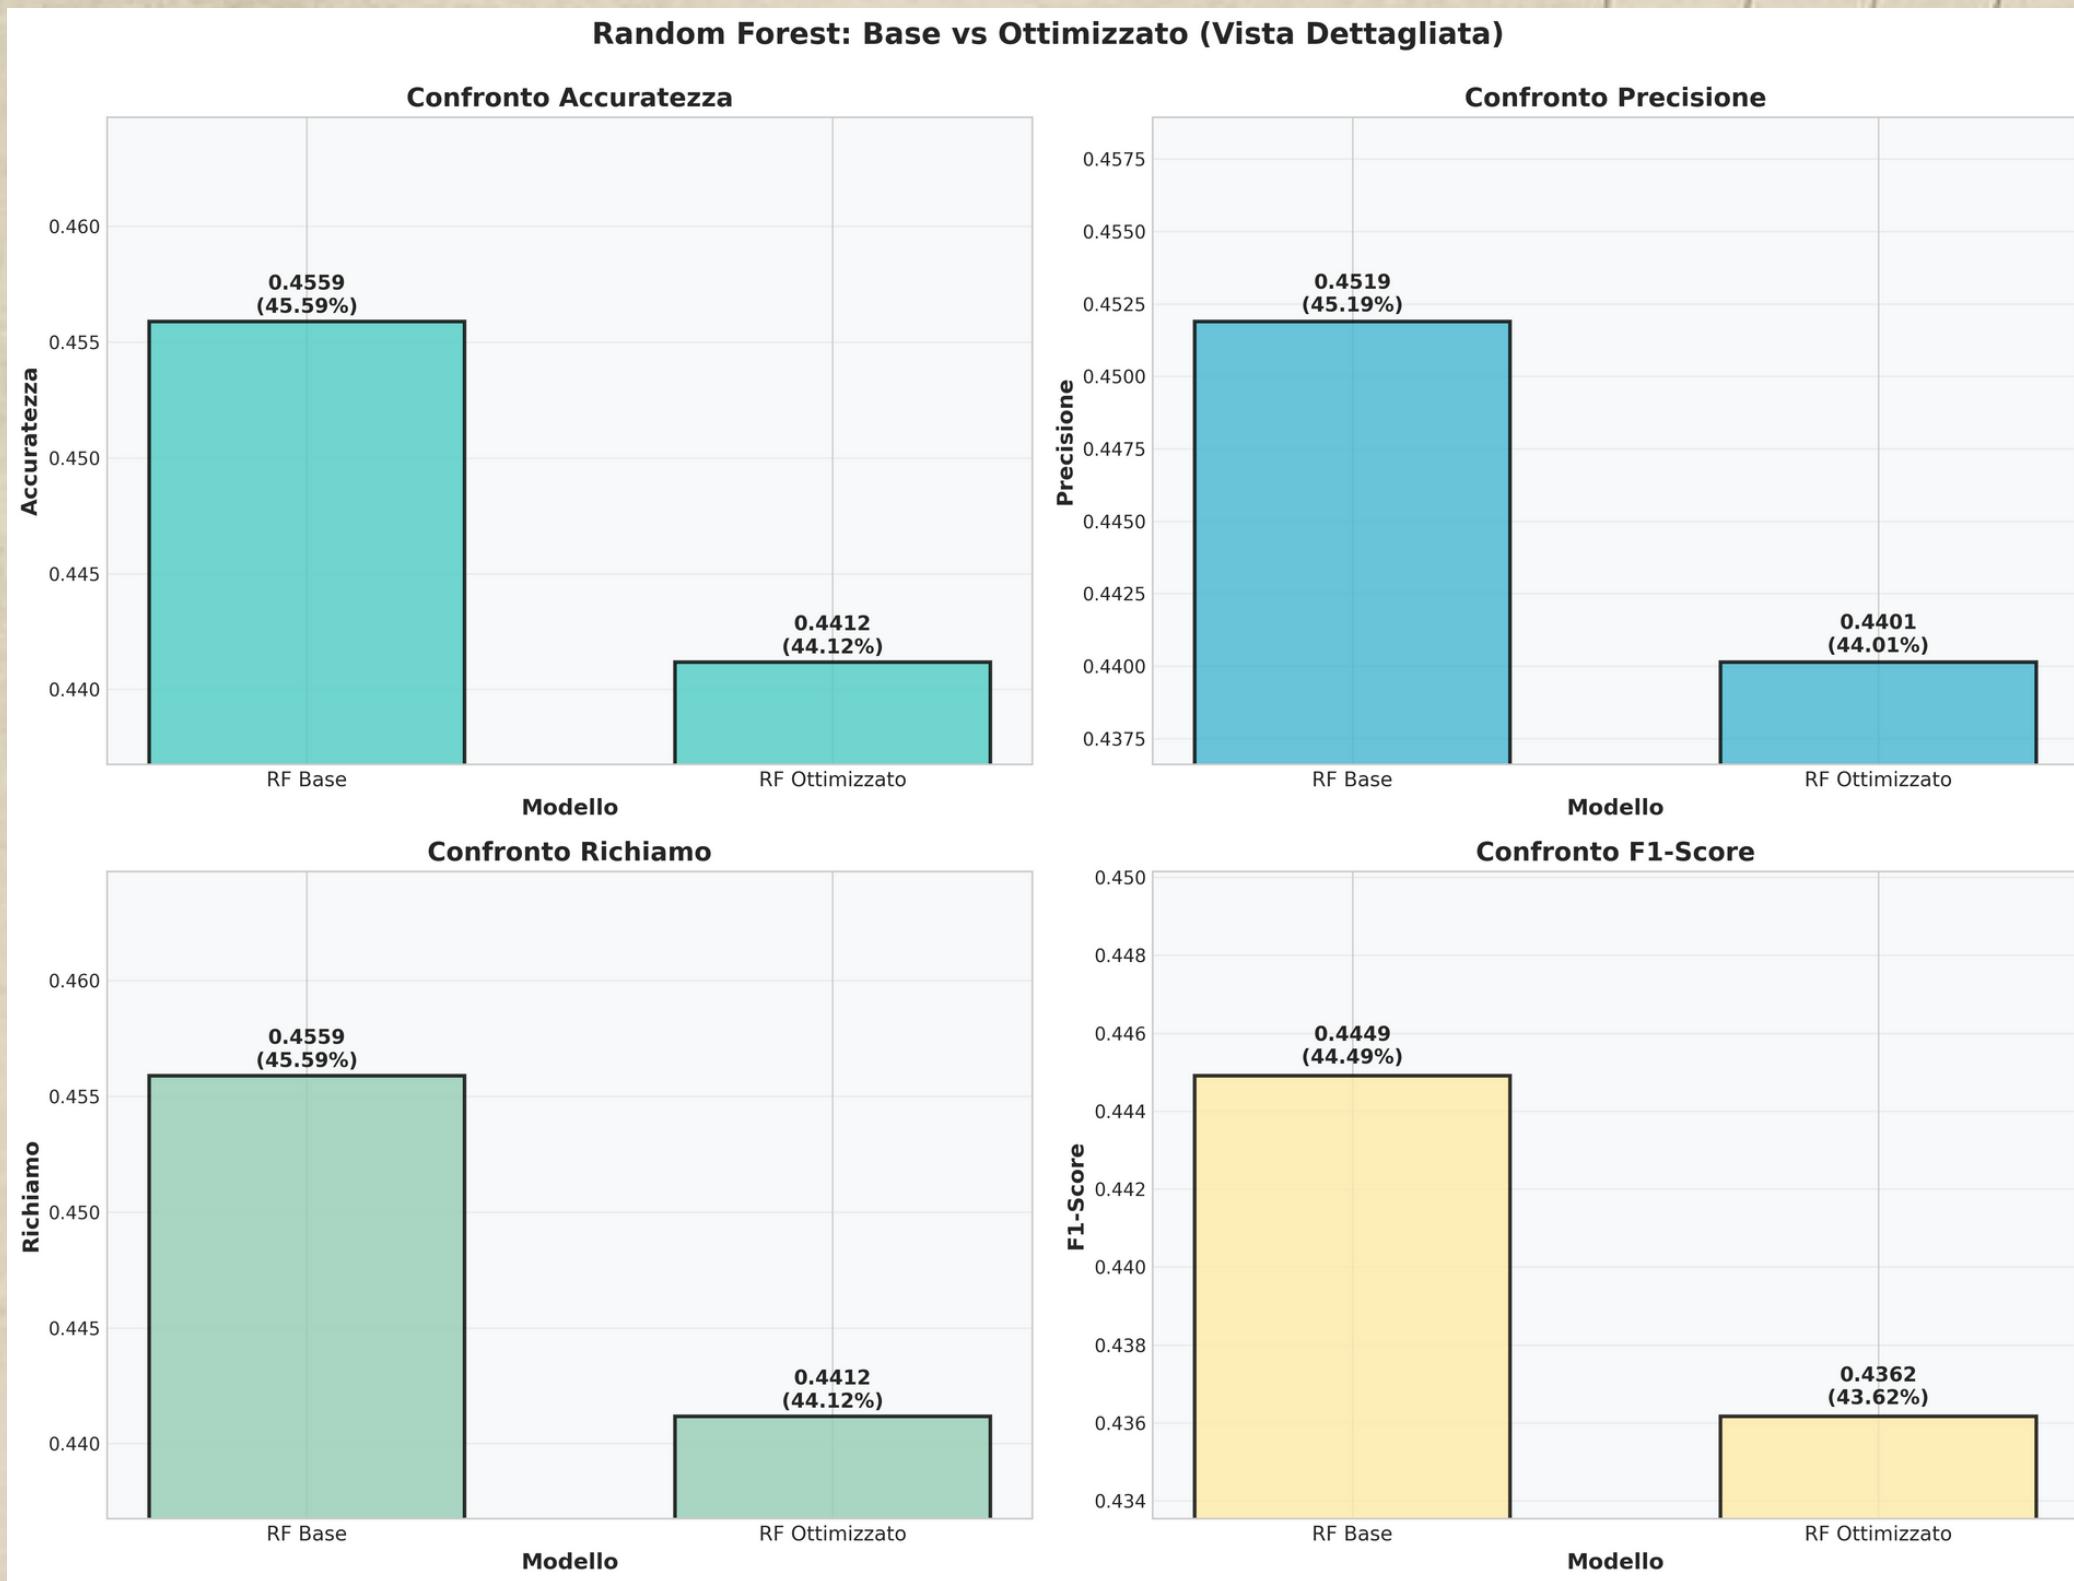


Random Forest Comparison - Detailed Metrics

| Model | Accuracy | Precision | Recall | F1-Score |
|--------------|----------------------|-----------|-----------|-----------|
| Baseline RF | 0.455882 (45.588%) | 0.451885 | 0.455882 | 0.444904 |
| Optimized RF | 0.441176 (44.118%) | 0.440135 | 0.441176 | 0.436167 |
| Difference | -0.014706 (-3.2258%) | -0.011749 | -0.014706 | -0.008737 |

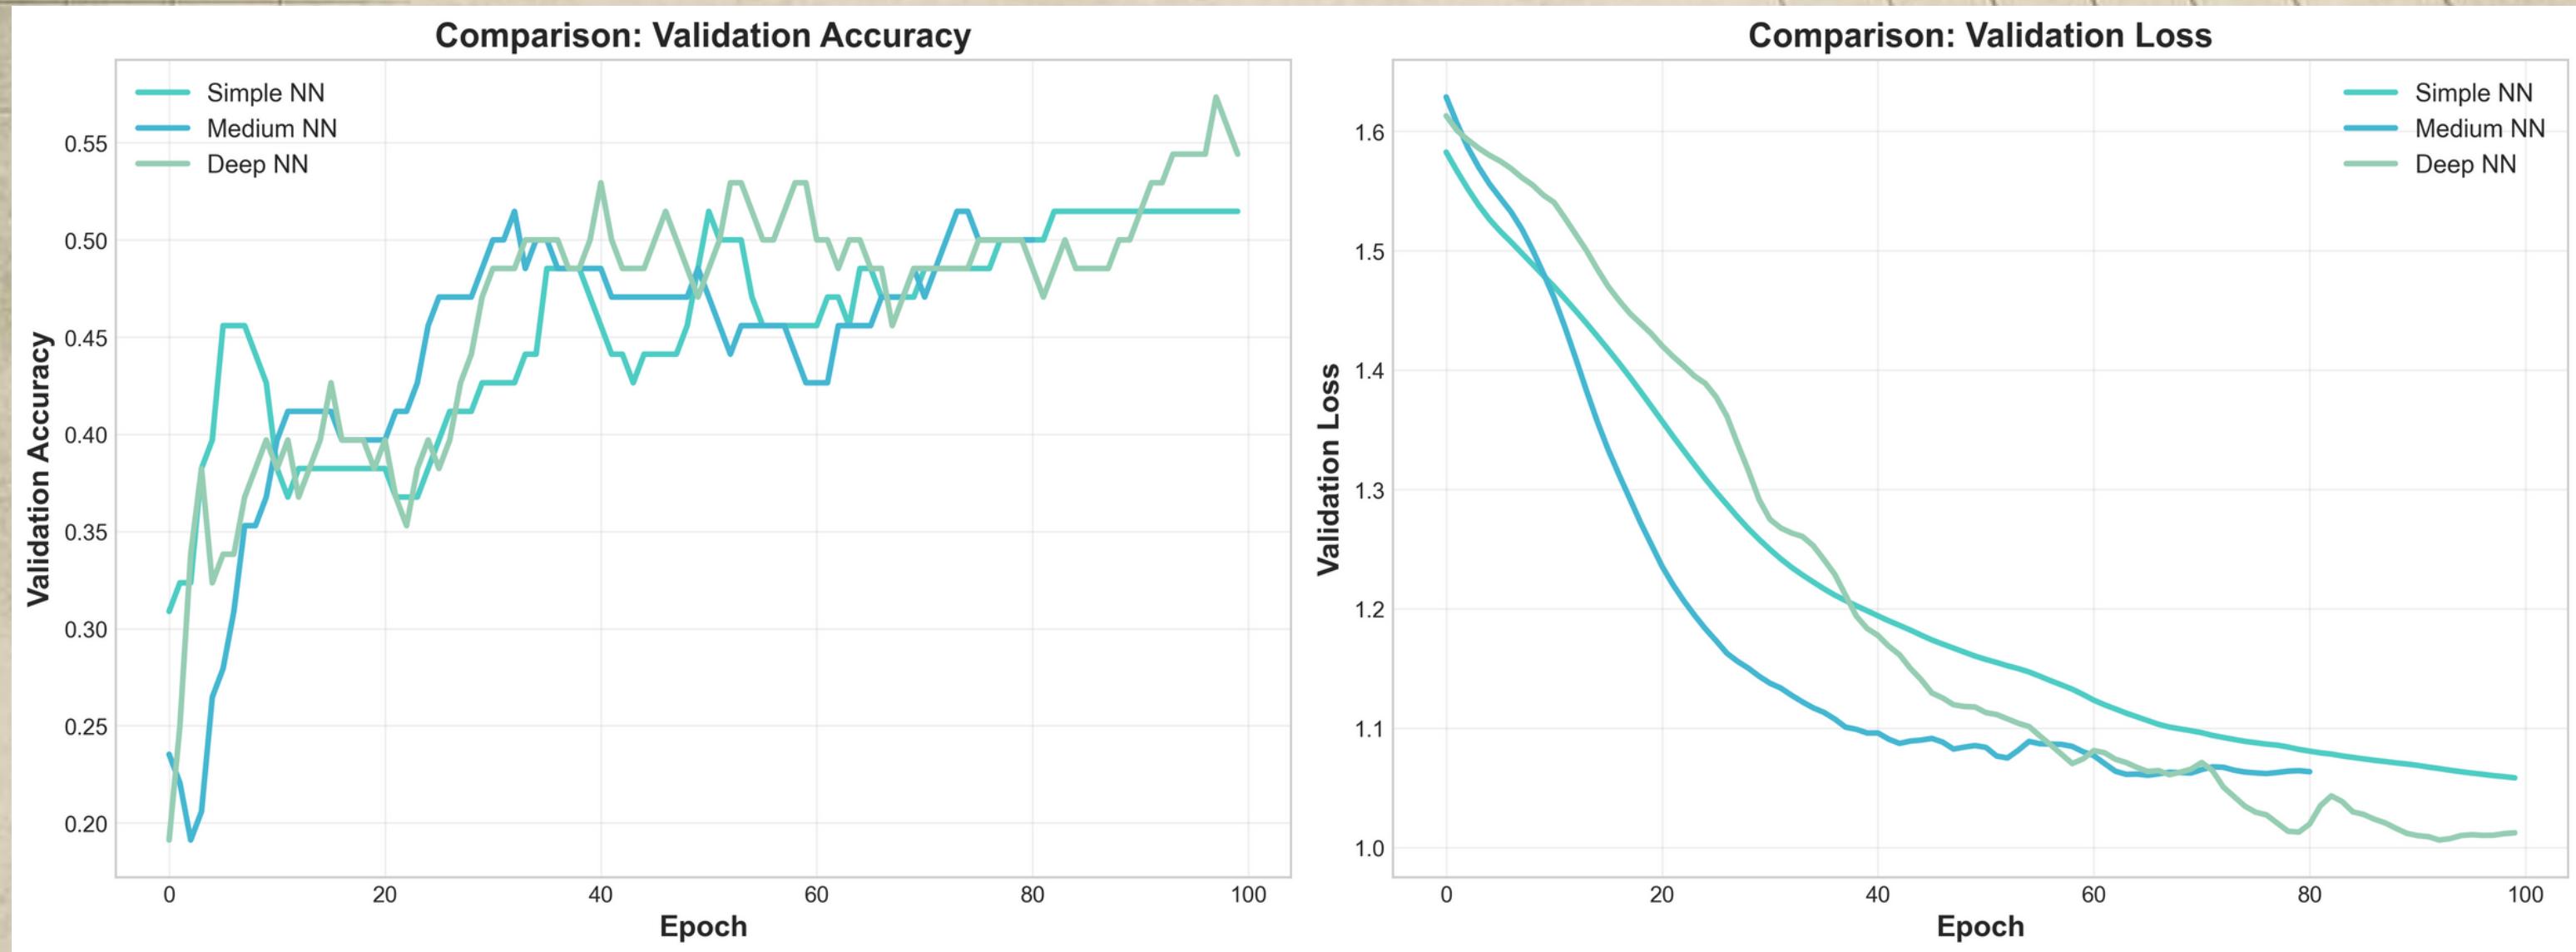


RANDOM FOREST



**Il RF ottimizzato è peggiore,
ma è normale!**
**Con un dataset piccolo (288
istanze) l'ottimizzazione può
peggiorare i risultati della
Random Forest (anche in
maniera molto lieve)**

RETI NEURALI

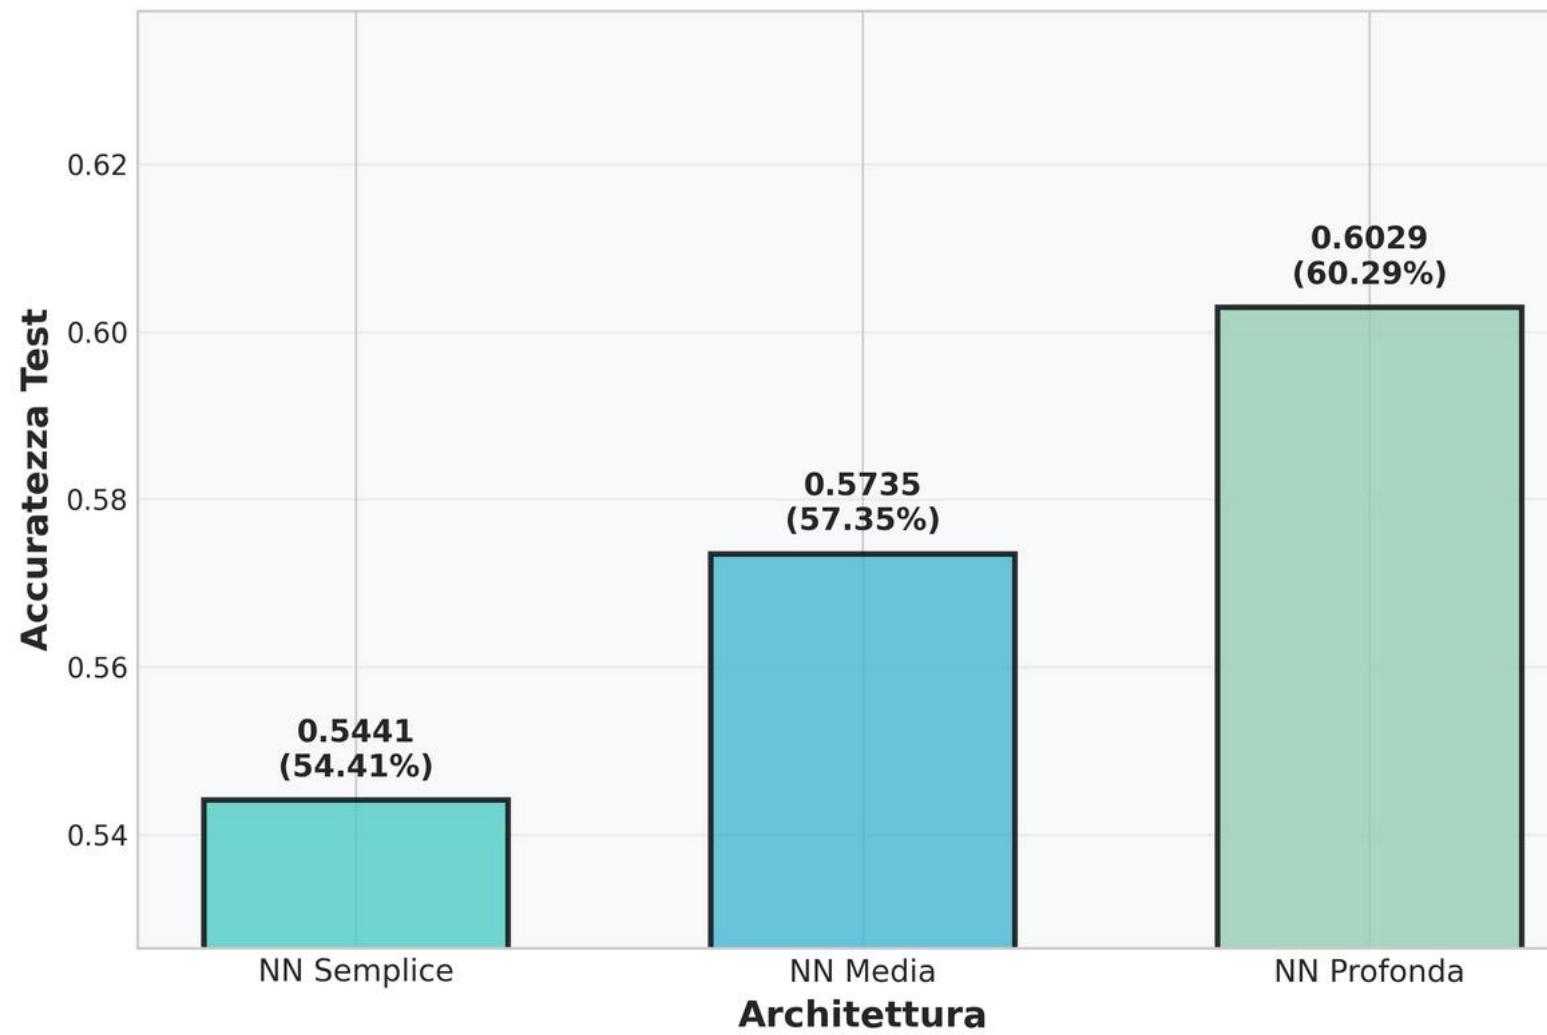


RETI NEURALI

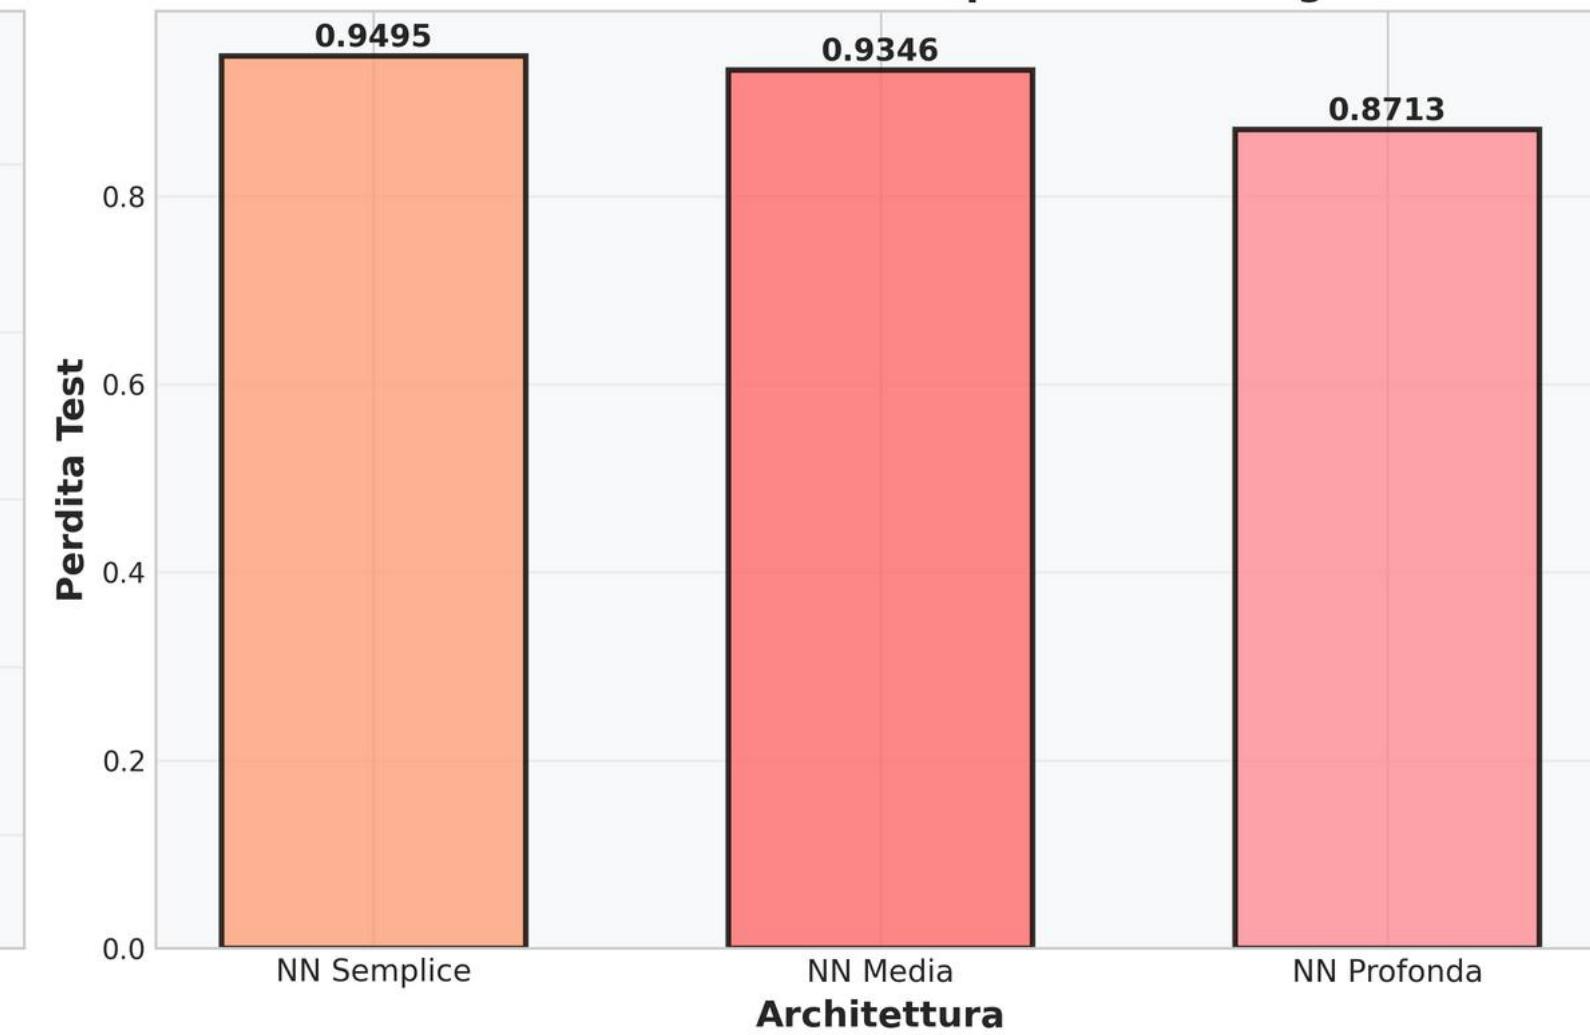
Confronto Prestazioni Reti Neurali



Reti Neurali - Accuratezza Test



Reti Neurali - Perdita Test (più basso è meglio)



2 hidden layers

3 hidden layers +
Dropout

4 hidden layers +
Batchnorm



RETI NEURALI



Training:

Modello migliore -> Architettura Profonda con Batch Normalization.

- Stabilizza l'allenamento normalizzando le attivazioni dei neuroni.
- Evita problemi di *gradienti esplosivi o vanishing*.
- Permette di usare tassi di apprendimento più alti senza instabilità.
- Ha un effetto di regolarizzazione, quindi riduce l'overfitting.
- Converge più velocemente e in modo più stabile

Dettagli Training:

- Ottimizzatore: **Adam (lr=0.001)**

Ottimizzatore adattivo che ha permesso di imparare in modo stabile e veloce. Con lr=0.001 abbiamo avuto convergenza rapida senza instabilità

- Loss: **Sparse Categorical Crossentropy**

Usata perché le etichette sono numeri interi. È la funzione giusta per classificazione multi-classe

- Callbacks: **EarlyStopping,**

EarlyStopping ha evitato l'overfitting fermando l'allenamento al momento giusto. ReduceLROnPlateau ha ridotto il learning rate quando la rete si bloccava, migliorando la precisione finale

ReduceLROnPlateau

- Epochs: **40–60 (interruzione anticipata)**

Massimo 60 epoche, ma con EarlyStopping il modello si fermava intorno a 40–50, quando la validazione non migliorava più

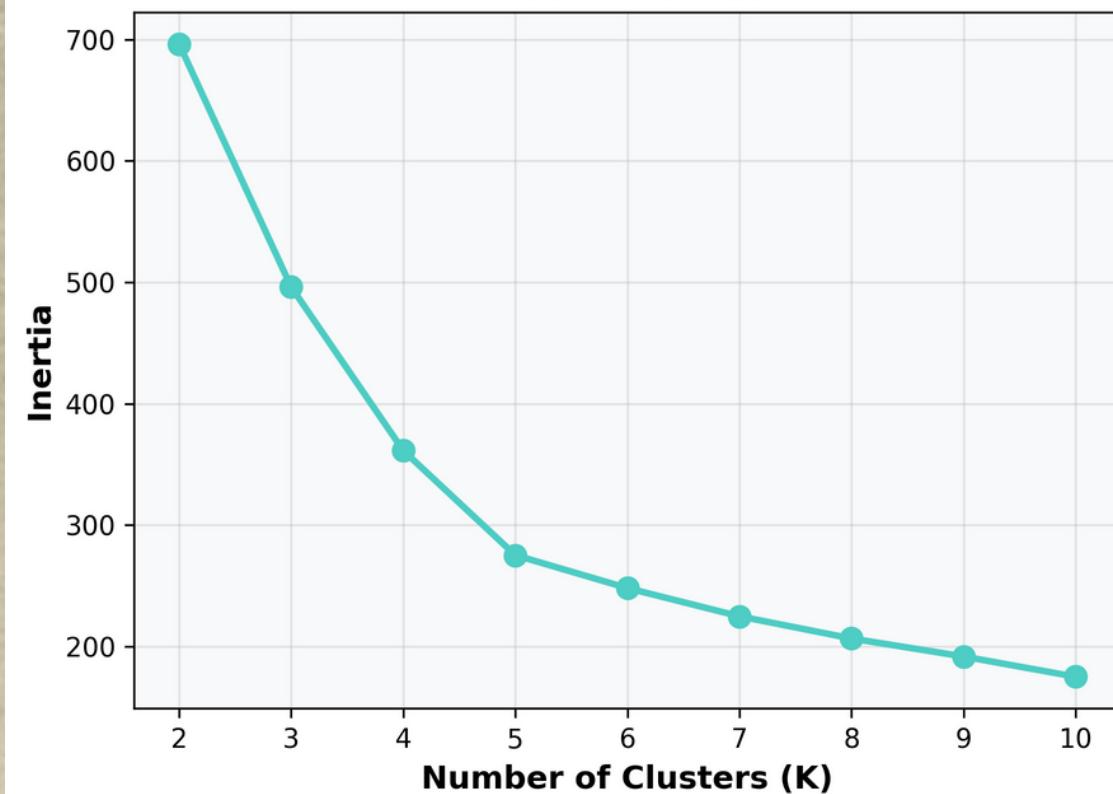


CLUSTERING

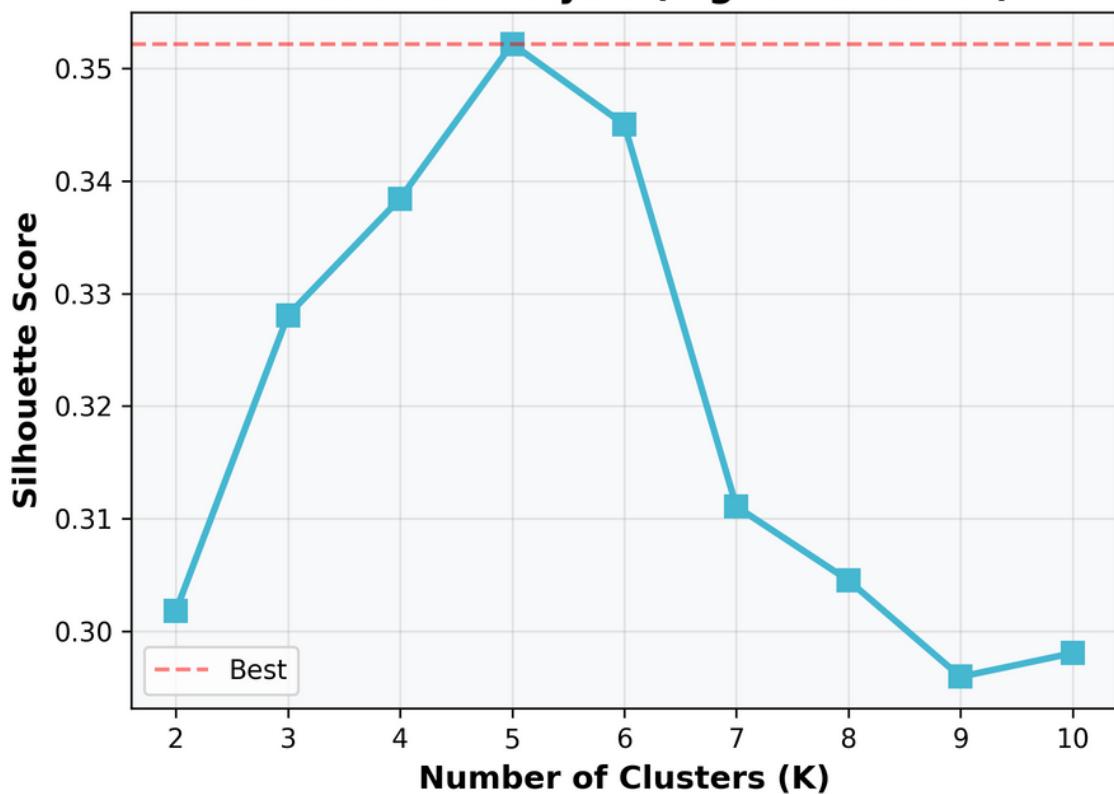


Optimal K Analysis

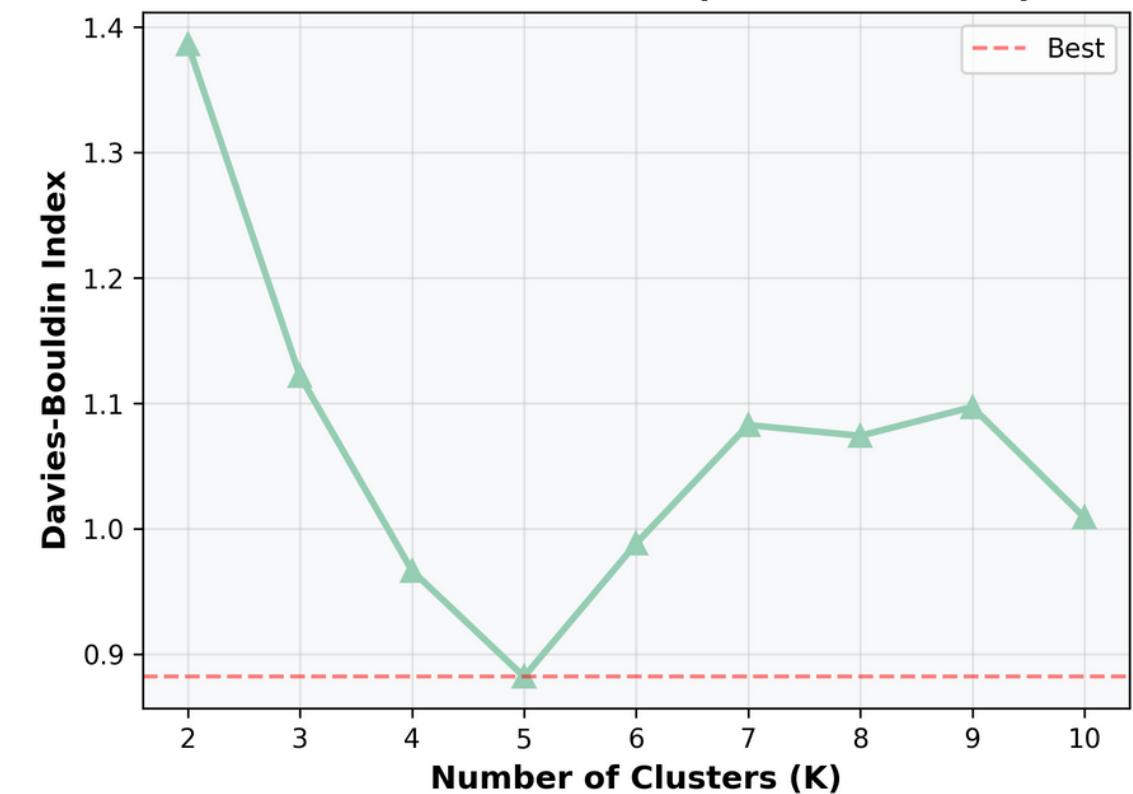
Elbow Method



Silhouette Analysis (higher is better)



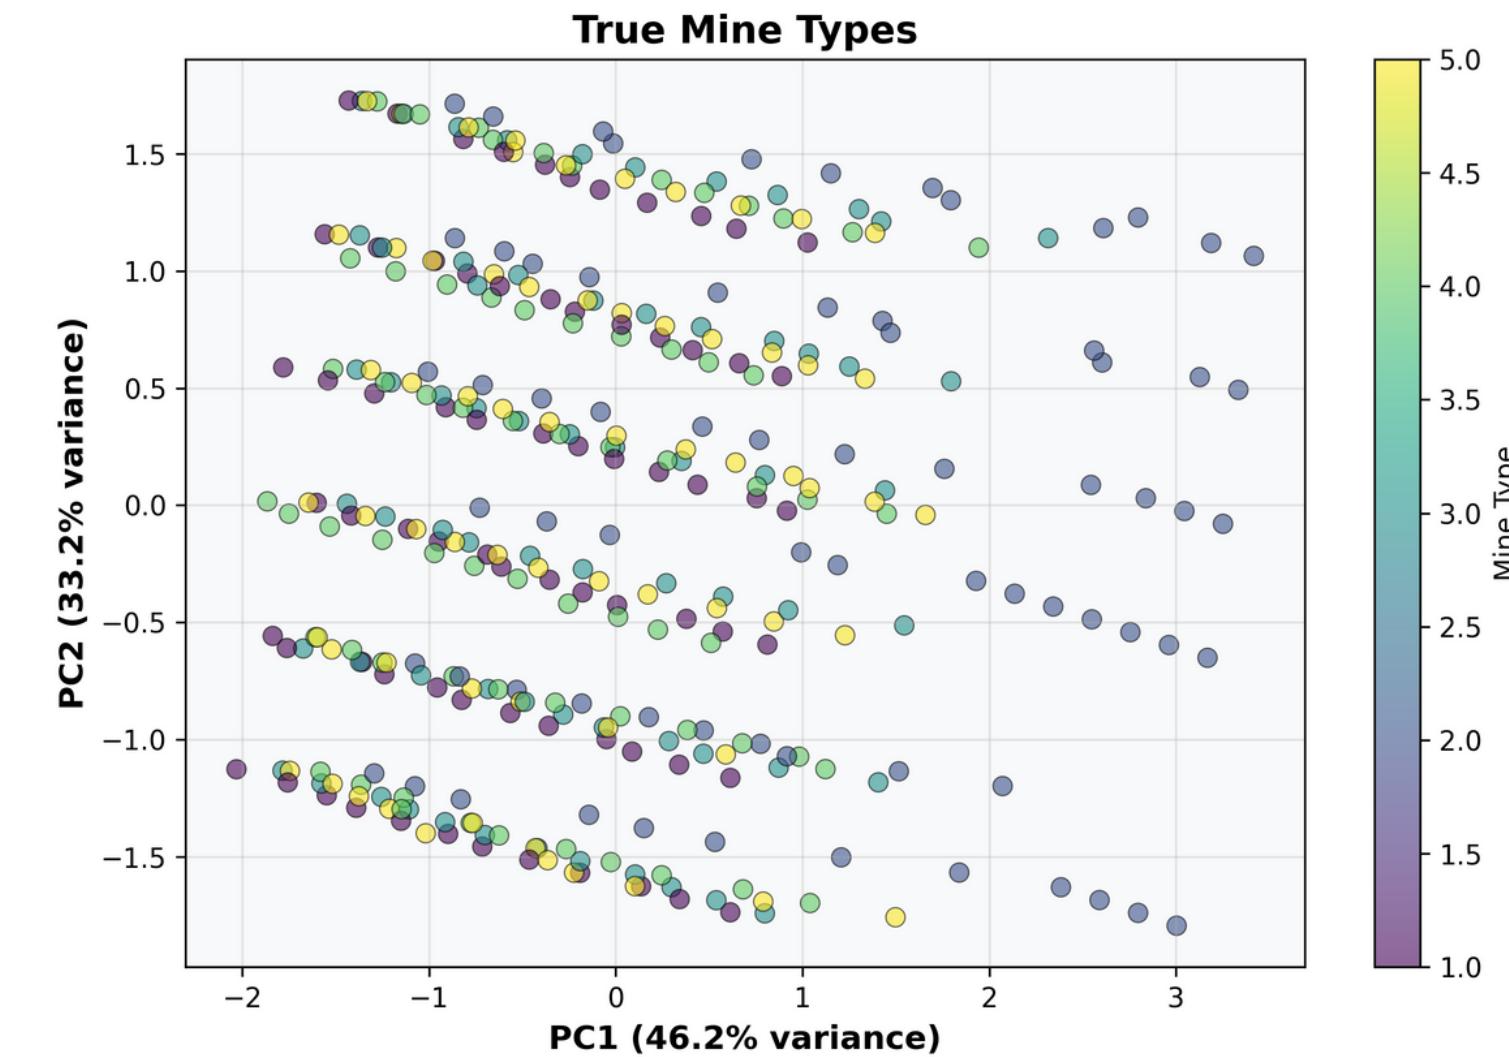
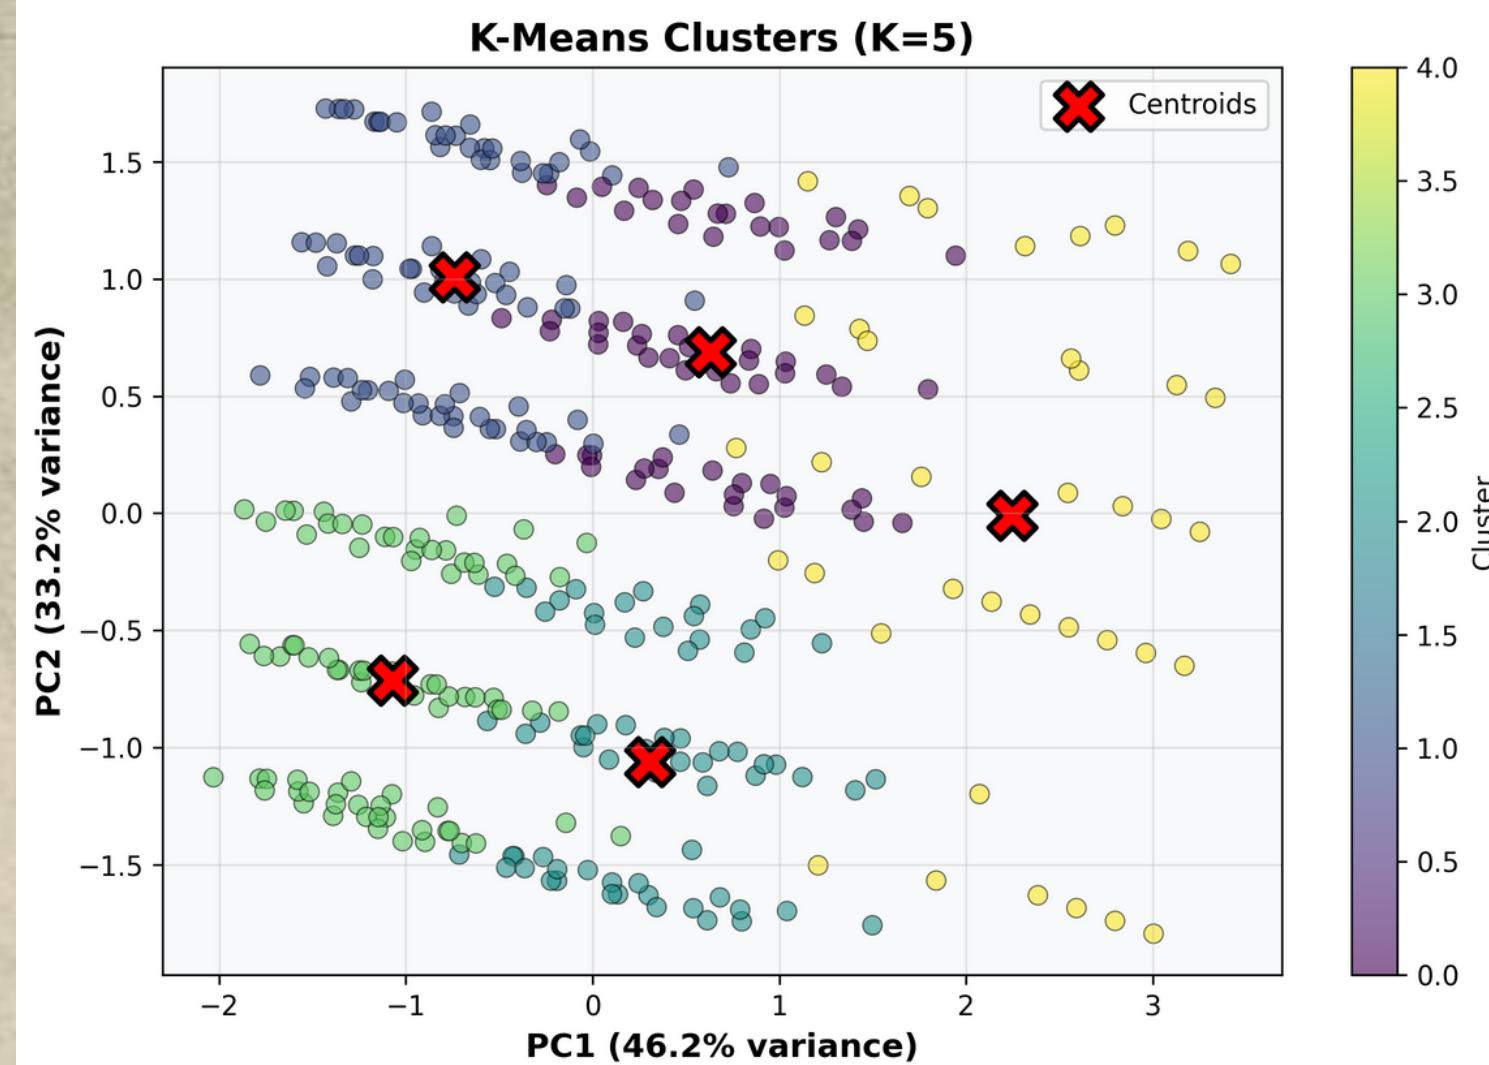
Davies-Bouldin Index (lower is better)



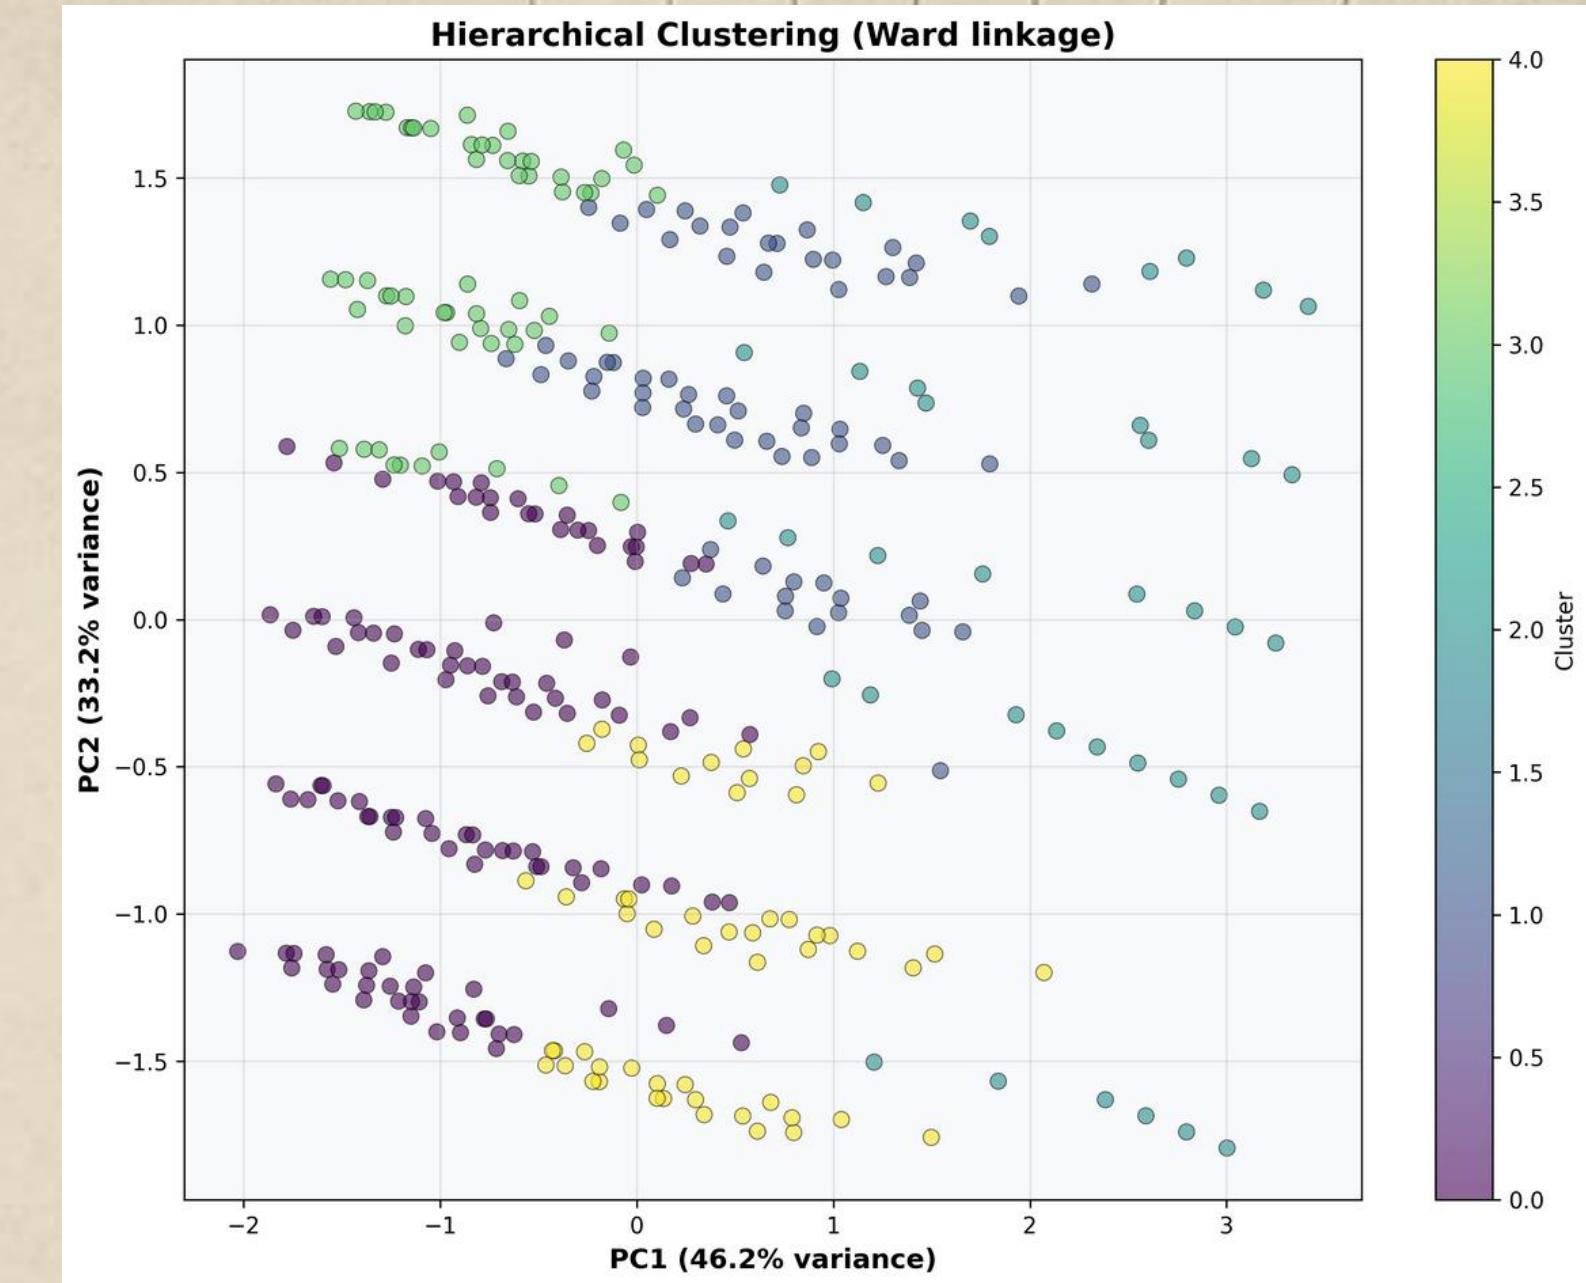
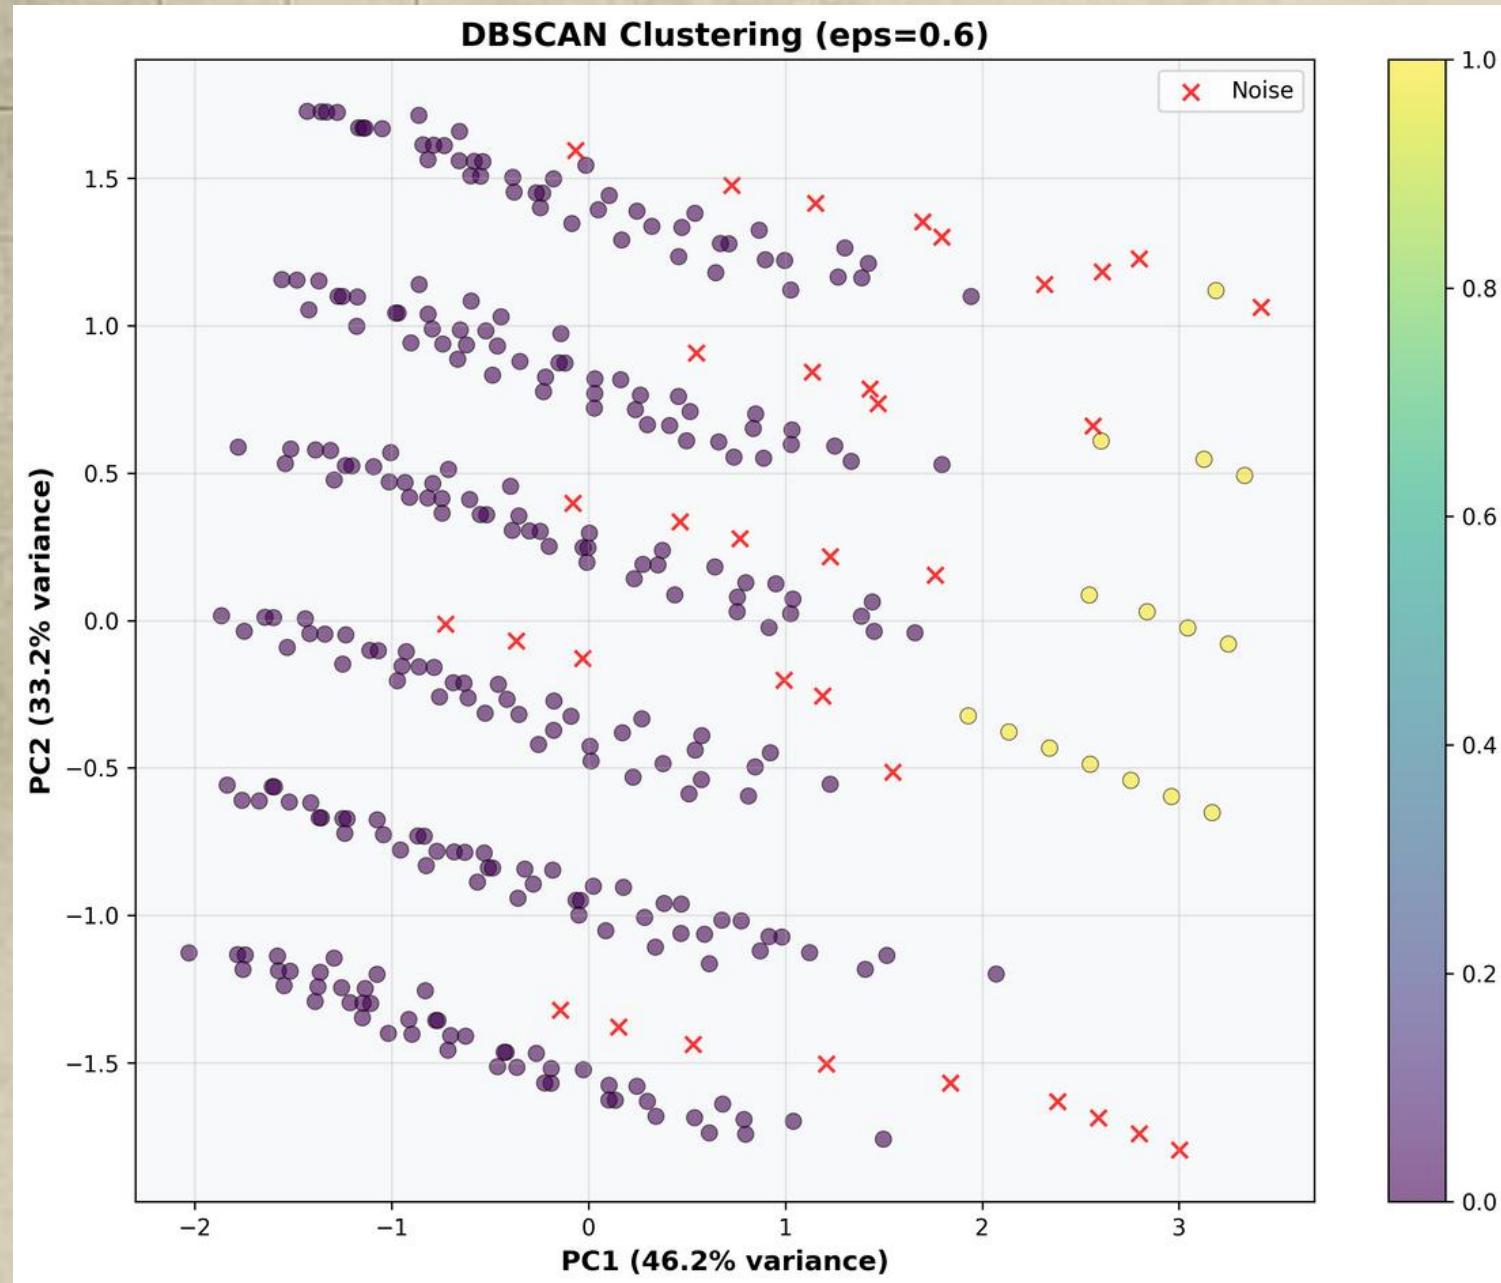
CLUSTERING



K-Means Clustering vs True Labels

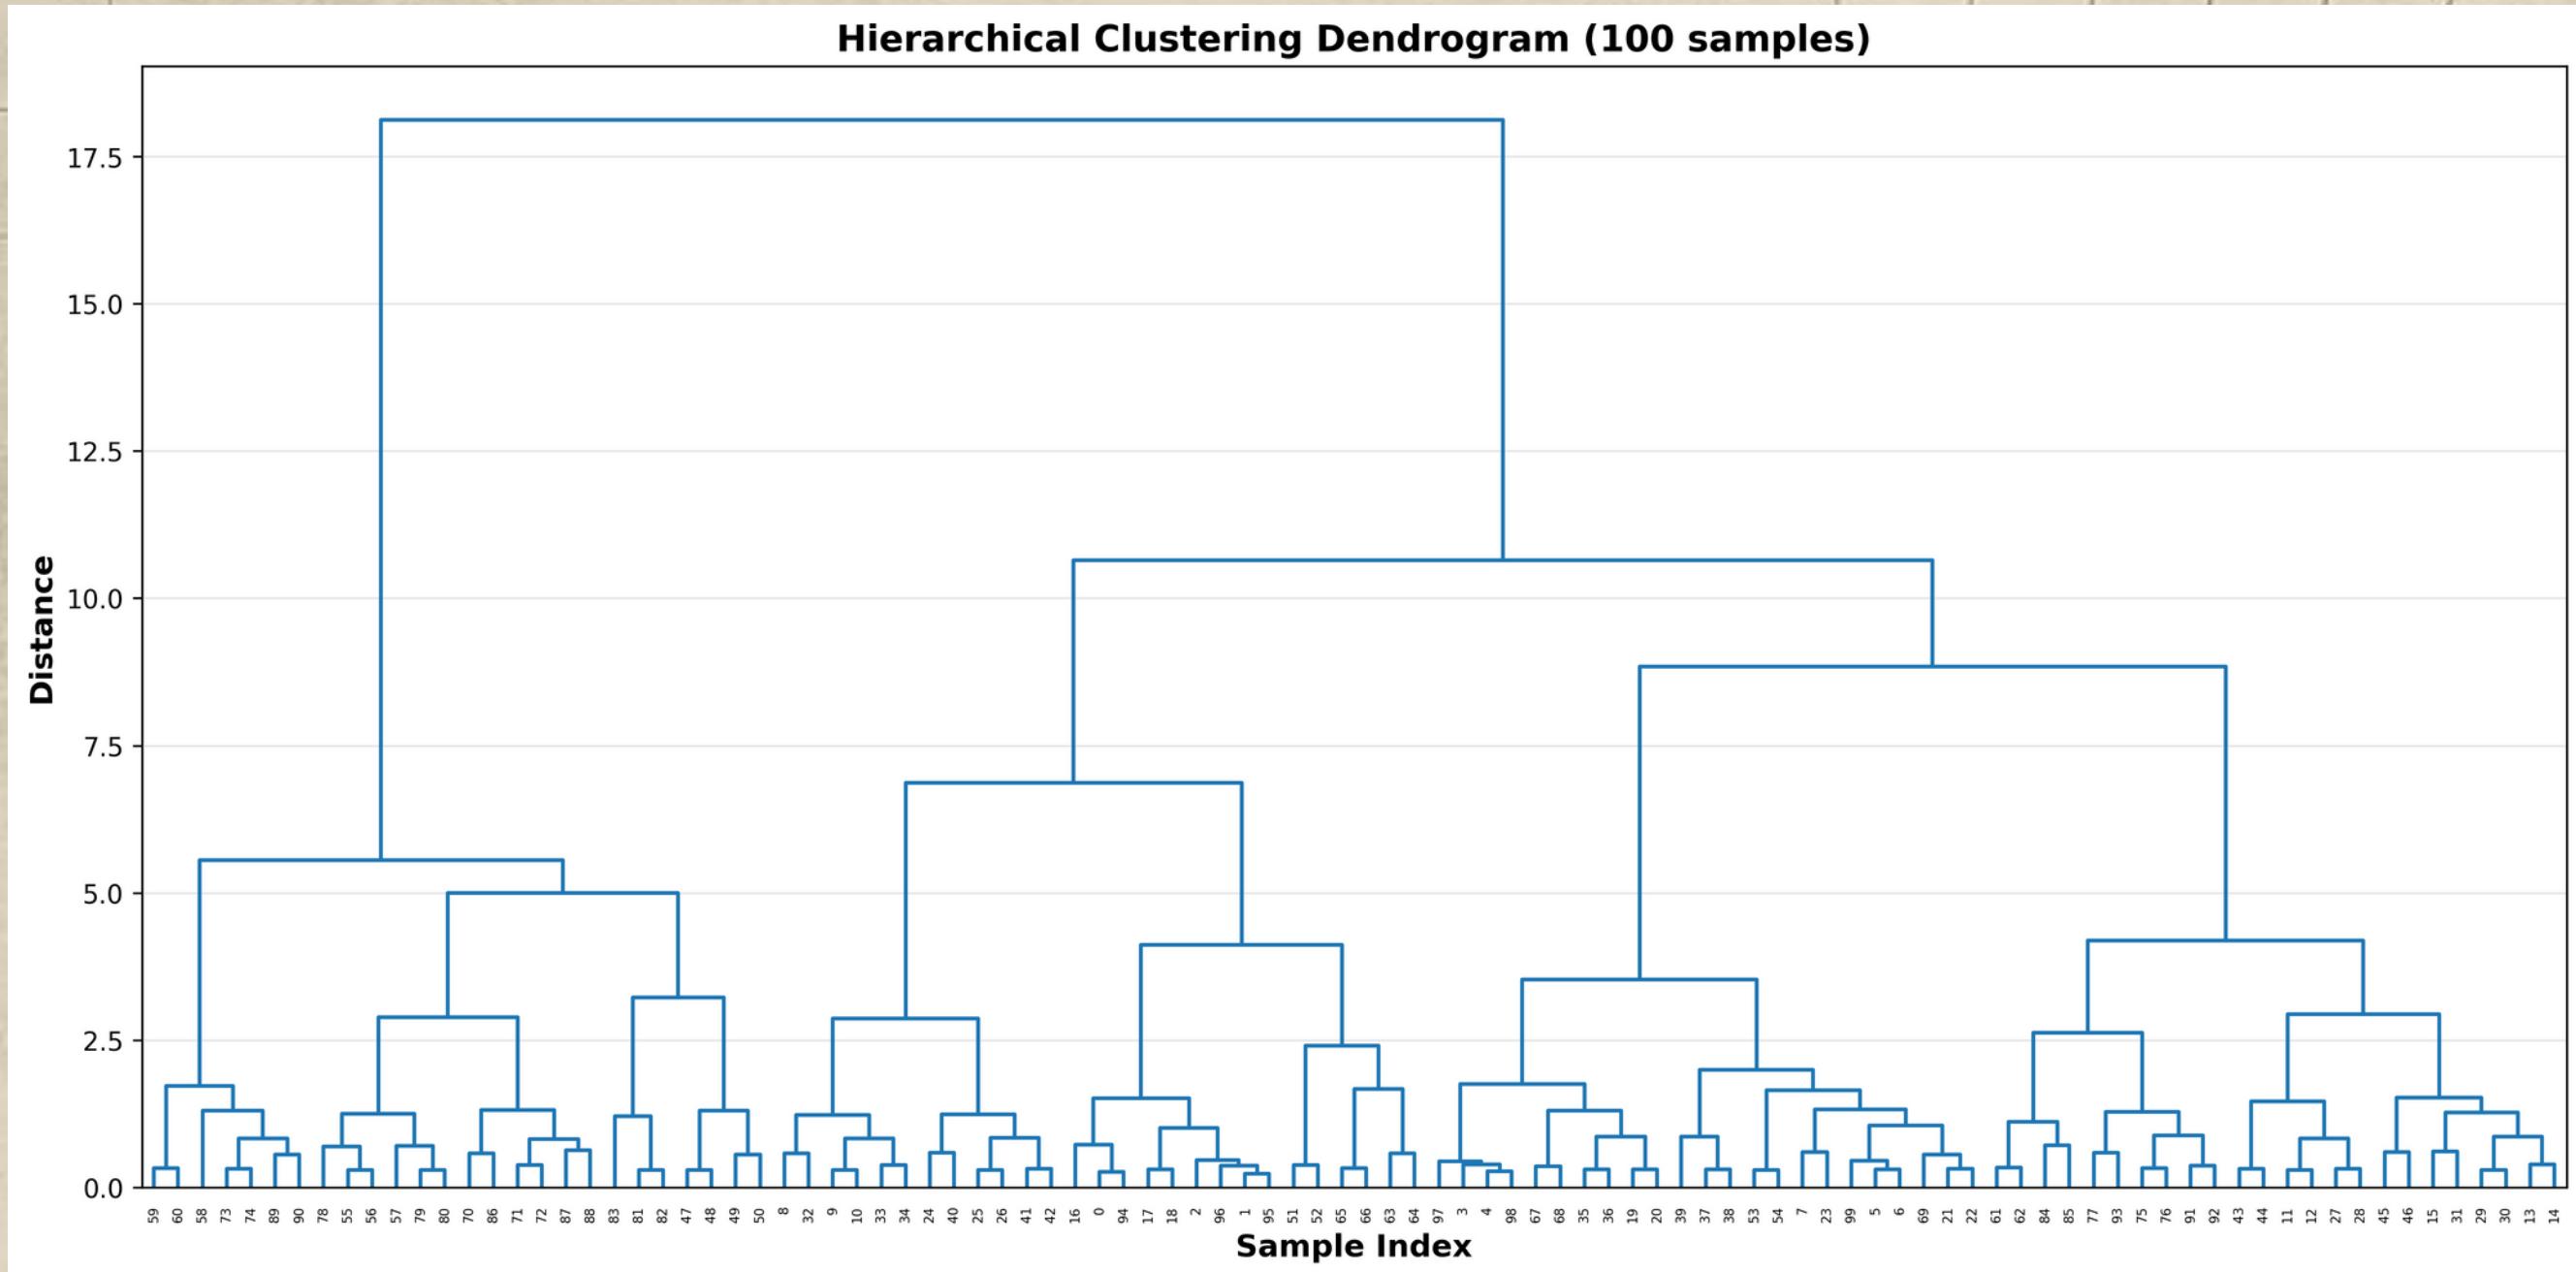


CLUSTERING



CLUSTERING

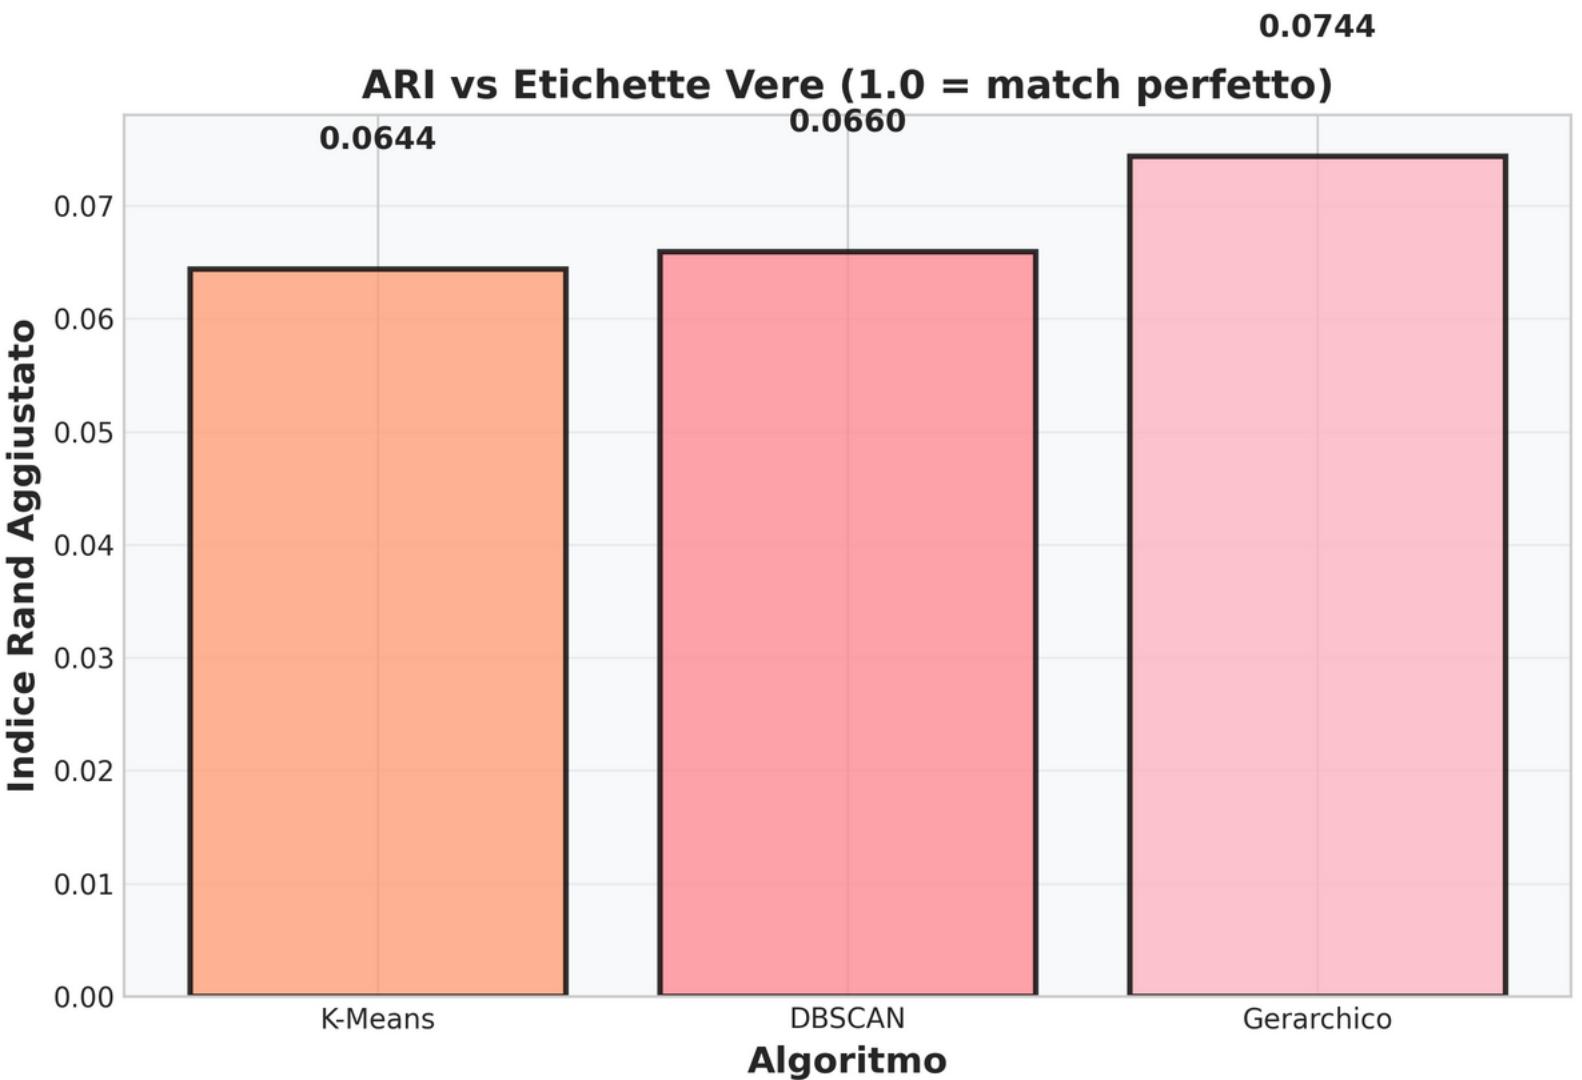
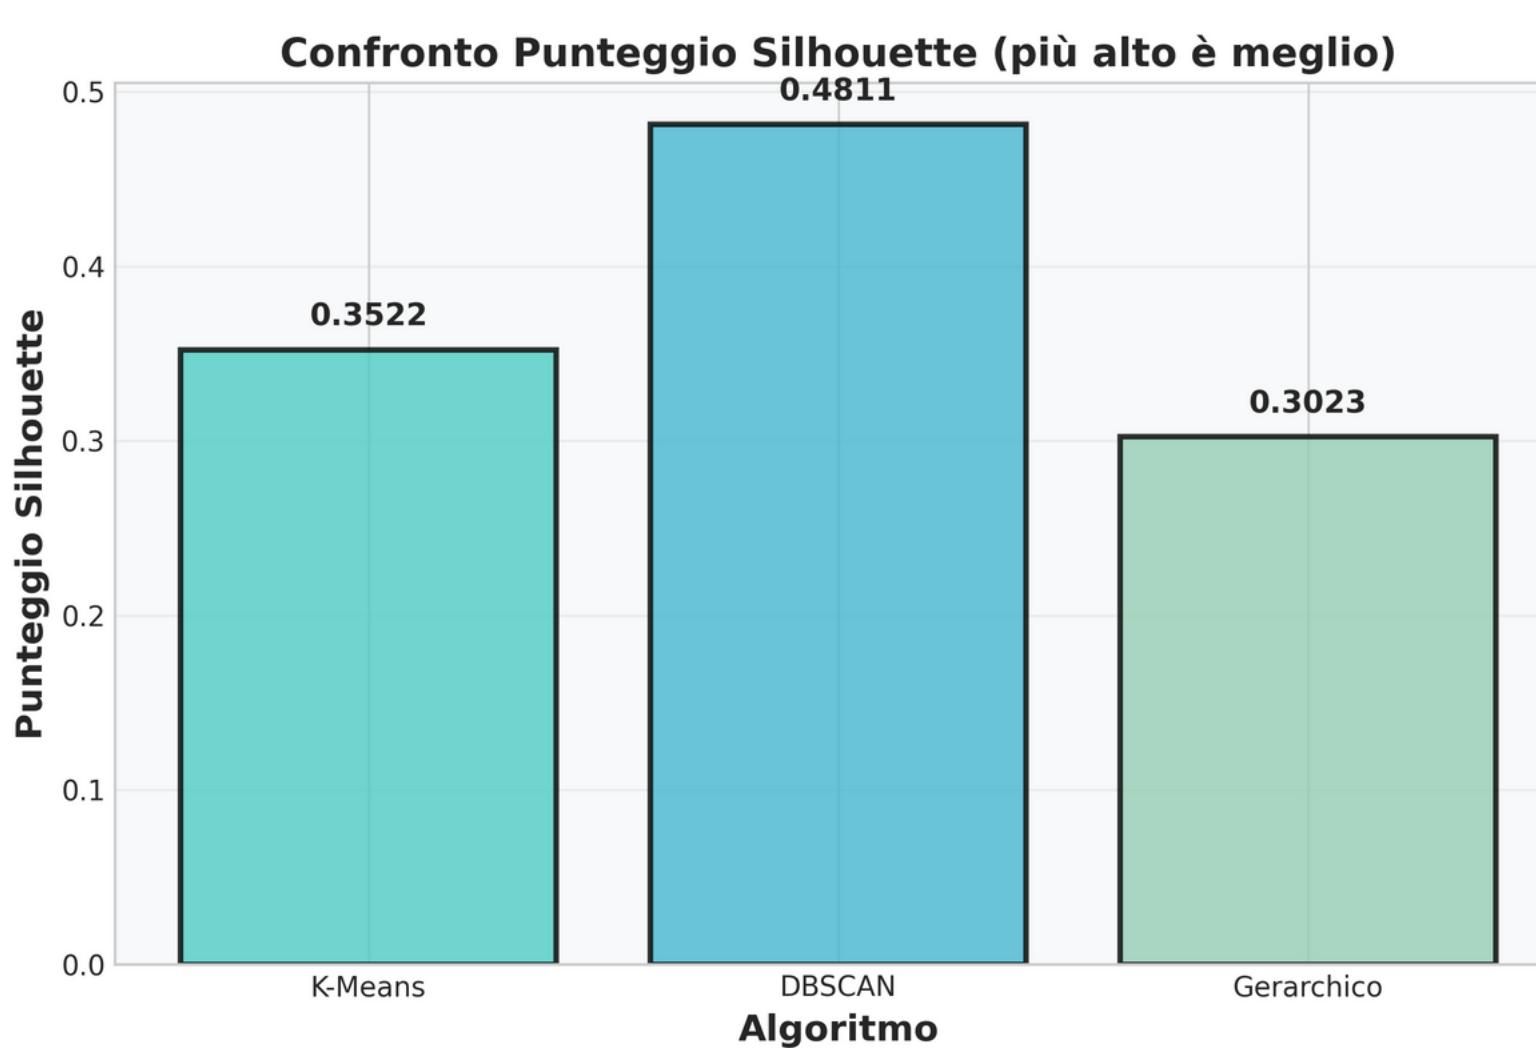
Hierarchical Clustering Dendrogram (100 samples)



CLUSTERING



Confronto Algoritmi di Clustering



I risultati sono discreti, ma per questo modello (non supervisionato) è normale non avere clusters precisi



RISULTATI CHIAVE

1. IMPORTANZA DELLE FEATURES

LA **TENSIONE (V)** È DI GRAN LUNGA LA **FEATURE PIÙ IMPORTANTE** (~85-90%), IL CHE INDICA CHE L'**INTENSITÀ DELL'ANOMALIA MAGNETICA** È IL PRINCIPALE INDICATORE DELLA PRESENZA E DEL TIPO DI MINA.



2. PERFORMANCE DEI MODELLI

- TUTTI I MODELLI **SUPERANO IL 99%**
- LA **DIFERENZA TRA RF BASE E OTTIMIZZATO È MINIMA**
- LA RETE NEURALE PROFONDA È **LEGGERMENTE SUPERIORE**

3. CLUSTERING

- **SILHOUETTE \~45%** (CLUSTERIZZAZIONE DISCRETA MA NON ECCELLENTE)
- IL **CLUSTERING GERARCHICO** MOSTRA IL **MIGLIOR ALLINEAMENTO CON LE ETICHETTE REALI**

4. IMPLICAZIONI PRATICHE

- ✓ RILEVAMENTO PASSIVO **ALTAMENTE EFFICACE E SICURO**
- ✓ LE **FEATURE SEMPLICI (V, H, S)** SONO SUFFICIENTI
- ✓ **PREDIZIONI RAPIDE** (ADATTE AD APPLICAZIONI REAL-TIME)



Risorse utilizzate e fonti

